



PI OS

高密部署智能体沙箱引擎

命题解决方案

目录

- 第一章执行总结 5
 - 1.1 命题情况 5
 - 1.2 项目背景 5
 - 1.3 项目规划 5
 - 1.4 市场分析 6
 - 1.5 行业竞争分析 6
 - 1.6 组织与人事分析 6
 - 1.7 财务分析 7
 - 1.8 风险分析 7
- 第二章项目简介 7
 - 2.1 命题内容 7
 - 2.2 项目概述 8
 - 2.3 项目进度 8
 - 2.4 项目使命 8
 - 2.5 项目业务简介 8
 - 2.6 战略目标 9
 - 2.7 发展规划 9
- 第三章核心痛点与技术解决方案 10
 - 3.1 命题约束与问题分析 10
 - 3.1.1 命题约束 10
 - 3.1.2 问题分析 10
 - 3.2 问题 1：运行时冗余 11
 - 3.3 解决方案 1：运行时扁平化 12
 - 3.4 问题 2：资源空转 13
 - 3.5 解决方案 2：动态资源卸载 14
 - 3.5.1 分层状态卸载：按状态类型实施保留与恢复 14
 - 3.5.2 按需状态恢复：由状态访问触发加载 14
 - 3.5.3 语义感知的实现路径 15
 - 3.5.4 实测效果 15
 - 3.6 问题 3：状态重复 17
 - 3.7 解决方案 3：智能内存共享 18

第四章市场与竞争分析	19
4.1 市场现状	19
1. 企业智能体应用正在扩大，配套运行需求随之增加	19
2. 沙箱服务已形成收费模式，细分方向获得资本关注	19
3. 企业仍在增加投入，但成本正在影响应用规模	19
4. 企业需求存在差异，为适配与交付服务提供切入点	20
4.2 市场前景	20
4.2.1 市场趋势和驱动因素	20
4.2.2 智能体运行服务的应用领域广泛	21
4.3 目标市场	22
4.3.1 PI OS 具有以下重要特点	23
4.3.2 PI OS 现阶段目标市场	23
4.4 商业模式	24
4.4.1 商业模式概述	24
4.4.2 客户细分	25
4.4.3 合作伙伴和资源	25
4.4.4 可持续发展和扩展性	25
4.4.5 收费模式	26
4.4.6 收费规则	26
4.5 竞争分析	27
4.5.1 世界竞争环境分析	27
4.5.2 国内竞争环境分析	27
4.5.3 竞争对手	29
4.5.4 SWOT 分析	29
第五章运营分析	30
5.1 质量评审	30
5.1.1 功能可行性	31
5.1.2 文档标准性	33
5.2 组织管理	33
5.2.1 创业初期	33
5.2.2 创业成长期	34
5.2.3 创业成熟期	35
5.3 人事管理	36

5.3.1 创业初期管理架构	36
5.3.2 创业发展及成熟期管理架构.	37
第六章财务分析与融资计划	37
6.1 基本会计与测算假设	38
6.2 收入预测.	39
6.2.1 年度产品服务收入	39
6.2.2 部署适配与生态合作	40
6.3 成本分析.	40
6.4 融资计划.	41
6.4.1 首轮资金需求	42
6.4.2 资金使用与分阶段控制.	43
第七章风险分析	44
7.1 风险识别.	44
7.1.1 市场风险.	44
7.1.2 操作风险.	45
7.1.3 财务风险.	45
7.1.4 法律风险.	45
7.1.5 数据与隐私风险	46
7.1.6 环境风险.	46
7.1.7 供应链风险.	46
7.1.8 风险评估矩阵	46
7.2 风险防范及措施	47
7.2.1 市场风险.	47
7.2.2 操作风险.	48
7.2.3 财务风险.	48
7.2.4 法律风险.	49
7.2.5 数据与隐私风险	49
7.2.6 环境风险.	50
7.2.7 供应链风险.	50
7.2.8 风险—对策映射汇总表.	51
7.3 风险资本退出	51
7.3.1 项目未达预期目标的退出策略	52
7.3.2 设定触发条件的退出策略.	52

7.3.3 保护投资者利益的退出策略	52
第八章团队介绍	52
8.1 主创团队	52
8.1.1 团队构成与能力互补	53
8.1.2 协作与质量控制机制	54
8.1.3 学生成长与项目持续性	55
8.2 指导教师	55
证明材料	56
补充证明材料	58

第一章执行总结

1.1 命题情况

命题题目：高密部署智能体沙箱引擎

命题企业：华为技术有限公司

命题组别：国产操作系统软件组

命题背景：智能体在完成代码修复、功能开发等任务时，需要通过沙箱提供独立、安全的工具执行环境。然而，多个沙箱重复部署运行环境，智能体等待大模型响应时仍持续占用资源，相同工具和基础状态也被重复保存，导致有限内存难以支撑大规模智能体并发运行。如何在保持任务正确性和沙箱隔离性的前提下提高部署密度，是本命题需要解决的核心问题。

命题内容：基于 openEuler/Conch + StratoVirt 运行 OpenClaw 智能体，在约定的 16GB 内存资源环境下，提高能够同时运行并完成指定任务的智能体数量。

答题要求：

1. 基于企业指定的 openEuler/Conch + StratoVirt 代码和容器镜像开展开发与验证。
2. 管理面与全部容器的总内存资源限制在 16GB 内。
3. 在沙箱内运行指定任务，例如代码修复或功能开发。
4. 每个沙箱内部可见规格为 2U8G，即 2 个虚拟 CPU、8GB 内存。
5. 关闭 Swap，不依靠交换空间扩大可用内存。

1.2 项目背景

PI OS 是面向企业智能体应用的高密部署沙箱引擎，致力于让同一台服务器安全、稳定地运行更多智能体。随着智能体逐步参与代码修复、功能开发和数据分析，企业不仅需要智能体“能够完成任务”，更需要解决“同时运行数量有限、资源占用高、扩容成本大”的问题。现有运行方式下，智能体即使处于等待状态，也往往持续占用资源；多个智能体使用相同工具时，还会重复占用空间，限制了有限硬件的服务能力。项目依托华为与天津大学的校企合作研究基础，围绕华为“高密部署智能体沙箱引擎”命题，在保障任务正确完成、不同任务互不干扰的前提下，提高资源利用效率，让有限的硬件承载更多任务，为企业规模化应用智能体提供支撑。

1.3 项目规划

PI OS 规划分为四个阶段：研发验证期、创业筹备期、市场拓展期和稳定发展期。目前项目已完成代码开发，正围绕企业命题开展测试优化，为后续产品交付和创业转化奠定基础。

研发验证期：在企业规定的环境下，验证系统能够同时承载的智能体数量、任务完成情况和运行稳

定性，完善部署工具、测试报告与使用文档，形成可演示、可部署、可验证的产品原型。

创业筹备期：明确合作成果的知识产权归属与商业化授权范围，推进创业团队建设和公司设立筹备。面向企业智能体平台、研发部门等潜在客户开展需求调研，确定首批服务场景，形成产品定位、报价方案和交付流程。

市场拓展期：在获得相应授权后，以小规模客户试点验证产品价值，重点展示同等硬件条件下任务承载能力的提升及实际使用成本的变化。通过部署适配、技术支持和持续维护等服务探索收入来源，积累可复制的客户案例。

稳定发展期：根据试点反馈完善产品与服务体系，逐步拓展客户和合作渠道，建立持续迭代、交付运维与客户支持能力，推动项目由技术成果转化为具有持续经营能力的创业企业。

1.4 市场分析

PI OS 面向企业智能体平台、软件研发团队及云服务商，聚焦“同样的硬件投入，能够支撑多少智能体完成任务”这一直接影响经营成本的问题。项目的商业切入点是提高已有平台的任务承载能力，帮助客户缓解扩容压力，为其提供可以通过任务数量、服务效率和使用成本衡量的采购价值。

1.5 行业竞争分析

从客户选择来看，PI OS 主要与现有云平台服务、企业自建运行环境及开源工具组合方案形成竞争。客户不仅关注产品能否运行智能体，更关注能承载多少任务、使用是否稳定、部署维护是否方便，以及长期投入是否划算。因此，项目的竞争重点是为客户提供可验证的成本与效率改善，而不是单纯增加功能。

PI OS 将“让同样的硬件完成更多任务”作为差异化定位，优先围绕代码修复、功能开发等明确场景开展验证。项目已完成代码开发，并具有校企合作研究基础，后续将通过客户试点积累实际使用数据，逐步形成产品适配、交付服务和应用经验方面的竞争优势。面对成熟平台的品牌与渠道优势，项目初期将集中服务需求明确的客户，通过小范围试点建立信任，再逐步扩大市场。

1.6 组织与人事分析

项目以学生创业团队为主体，依托校企合作研究基础，推动技术成果向可交付产品转化。团队涵盖计算机科学与技术、软件工程、人工智能、网络安全等专业背景，围绕产品研发、测试验证、客户需求和经营管理开展协作，兼顾产品能力与创业落地。

现阶段重点是完善产品、验证企业需求并建立交付流程，采用职责明确、沟通直接的协作方式，控制组织成本。随着客户试点推进，逐步明确产品研发、市场拓展、客户服务和财务管理等岗位职责，按实际业务需要补充人才，避免在收入尚未稳定前过快扩张。通过统一的工作计划、成果检查和资料交接机制，保障项目持续推进。

1.7 财务分析

项目现阶段以产品完善、测试验证和创业筹备为主要投入方向。已有校企科研合作协议约定研发经费为 **113.3 万元含税**，体现了研究任务的合作基础；该金额属于科研合同约定，不计入创业企业销售收入，也不等同于已到账资金。

创业初期将优先利用现有研发成果控制重复投入，根据客户试点进度安排支出。在明确商业化授权后，探索部署适配、技术支持和年度维护等收入来源，逐步形成“一次性交付收入与持续服务收入相结合”的经营模式。

1.8 风险分析

项目主要面临市场转化、产品交付、资金周转和成果使用四方面风险。企业认可技术价值，并不意味着立即采购；产品在测试环境中的表现，也需要在客户实际任务中进一步验证。此外，客户付款周期可能影响资金安排，合作研究成果的商业使用和公开展示也需要取得相应授权。

针对上述风险，项目将优先开展小规模试点，以实际任务完成情况、运行稳定性和综合成本验证客户价值，再逐步扩大交付范围。资金使用与研发、试点和订单进度相匹配，减少提前扩张带来的经营压力；对商业化和对外宣传涉及的成果，提前确认使用权限，确保合作与经营合规。

第二章项目简介

2.1 命题内容

人工智能正在从提供信息和辅助决策，向参与实际业务执行发展。代码修复、功能开发、数据分析等场景，不仅需要模型给出答案，还需要智能体调用工具、执行操作并完成任务。Gartner 于 2025 年发布预测，到 2026 年底，40% 的企业应用将集成面向特定任务的智能体，而发布预测时这一比例不足 5%。智能体应用范围的扩大，也将带动对配套运行环境和基础服务的需求。

然而，应用需求的增长并不意味着智能体能够直接实现规模化落地。Gartner 指出，部署成本上升、商业价值不明确以及风险控制不足，是智能体项目推进过程中面临的重要障碍。从企业实际使用角度看，智能体的价值不仅取决于单次任务能否完成，还取决于能否同时服务多个用户、持续稳定运行，以及投入与产出是否匹配。因此，支撑智能体运行的基础软件，需要在功能、安全、效率和成本之间形成适合企业使用的平衡。

与此同时，云计算为智能体应用提供了集中部署和规模化服务的基础。中国信息通信研究院《云计算蓝皮书（2025 年）》列示，2024 年全球云计算市场规模达到 6929 亿美元，人工智能的发展正在持续带动云计算需求。在这一产业背景下，提高已有基础设施的任务承载能力，成为智能体运行服务的重要发展方向。华为技术有限公司围绕国产操作系统软件生态，提出“高密部署智能体沙箱引擎”命题，要求在有限资源条件下，为更多智能体提供独立、可靠的任务执行环境。

本课题旨在探索适合智能体任务特点的新机制、新方法和基础软件，提升有限硬件条件下的智能体部署与服务能力。项目基于企业指定的 openEuler/Conch + StratoVirt 环境运行 OpenClaw，在管理面与全部容器总内存限制为 16GB、每个沙箱内部可见规格为 2U8G、关闭 Swap 的条件下，支持代码修复、功能开发等指定任务。在保障任务正确完成、不同任务互不干扰的基础上，提高能够同时运行的智能体数量，为企业以可控投入扩大智能体应用规模提供支撑。

2.2 项目概述

PI OS 是面向企业研发团队与智能体服务平台的高密部署智能体沙箱引擎。项目依托华为与天津大学的校企合作研究基础，围绕代码修复、功能开发等应用场景，为智能体提供独立的任务执行空间，支持多个智能体同时开展工作，保障不同任务之间互不干扰。项目已完成代码开发，正围绕企业规定的环境开展测试优化，致力于为企业提供稳定、可靠、便于部署的智能体运行基础。

PI OS 以“让同样的硬件完成更多任务”为核心目标，将资源利用效率与企业实际使用需求相结合。在保障任务正常执行的前提下，通过更合理地组织运行环境和分配资源，提高有限服务器的任务承载能力，减少企业对持续扩充硬件的依赖。项目不仅关注智能体“能否运行”，更关注其能否以可控成本持续服务更多用户，力求推动智能体从单个任务试用走向企业规模化应用，为国产操作系统生态下的智能体服务提供可行的产品方案。

2.3 项目进度

目前，PI OS 已完成代码开发，并形成系统设计材料和阶段测试报告。前期研究环境下，已开展 48 个任务的并发测试，报告记录任务全部完成，未发生内存不足导致的中断；在相同 48 个任务的补充测试中，总完成时间由约 735 秒缩短至 245 秒，缩短约 66.7%。下一阶段将围绕华为指定运行环境开展适配与验证，进一步确认在 16GB 总内存限制下的智能体承载能力，完善部署工具和交付文档，为企业试点与产品转化奠定基础。

2.4 项目使命

PI OS 的使命，不仅是让有限的硬件承载更多智能体，更是立足国产基础软件生态，以自主创新服务国家科技自立自强。项目坚持从真实需求出发，让智能体用得起、用得好、用得安心，帮助企业降低应用门槛，为科研探索和产业创新提供可靠支撑。让有限的计算资源服务更多创新，让技术进步惠及更多用户，为我国数字经济发展贡献青年力量。

2.5 项目业务简介

PI OS 的目标客户首先是具有智能体应用需求的企业研发团队和高校科研团队，优先围绕代码修复、功能开发等场景开展试点。在完成产品验证并明确商业化授权后，逐步面向智能体服务平台、云服务商及其他有需求的企业推广。

PI OS 为客户提供智能体运行与管理能力，支持多个任务同时开展，并为不同任务提供相互独立的执行空间。产品以提高有限硬件的任务承载能力为核心，帮助客户更充分地利用已有服务器，兼顾任务完成效率、运行稳定性和使用成本。

客户完成产品部署与任务接入后，即可利用 PI OS 支撑智能体执行工作，并查看任务结果与资源使用情况。项目拟配套提供部署指南、使用文档、技术支持和持续维护服务，降低客户的接入与维护负担，逐步形成从试点验证到正式交付、长期服务的业务模式。

2.6 战略目标

PI OS 力争在十年内成长为具有国际竞争力的国产智能体运行基础软件品牌，成为企业规模化部署智能体的重要选择。让更多企业和科研团队以可控成本用好智能体，让有限的计算资源支撑更多创新，为我国基础软件自主发展和产业智能化升级贡献力量。

2.7 发展规划

PI OS 自 2026 年启动以来，围绕华为“高密部署智能体沙箱引擎”命题，已完成代码开发并形成阶段测试材料。项目将按照“研发验证—创业落地—市场拓展—持续发展”的路径，逐步由技术原型成长为面向企业交付的产品，推动科研成果与实际应用需求相结合。

表 2-1 PI OS 发展规划

发展阶段	时间	主要内容
准备期	2026 年	完成项目立项、需求分析和代码开发，形成产品原型与阶段测试材料。围绕企业指定环境开展适配，验证有限内存条件下的任务承载能力与运行稳定性。完善部署工具、测试报告和使用文档，完成竞赛展示与创业方案论证。
创业期	2027 年	明确成果商业化授权范围，推进公司设立和创业团队建设。面向企业研发团队、高校科研团队开展客户调研与小规模试点，根据反馈完善产品。建立报价、交付和售后服务流程，探索部署适配、技术支持与年度维护等收入来源，争取形成首批付费客户案例。
成长期	2028 年至 2030 年	将试点经验转化为可复制的产品和交付方案，逐步拓展企业智能体平台及云服务商客户。完善产品功能、稳定性和维护能力，支持更多实际任务场景。建设市场与服务渠道，通过持续服务和客户续约，推动业务由单次项目交付向持续经营发展。
稳定发展期	2031 年及以后	持续跟进智能体应用需求，提升产品效率、可靠性和易用性，完善长期支持体系。深化与国产操作系统、云服务及智能体应用生态的合作，扩大产品覆盖范围。在国内形成稳定业务基础后，逐步探索海外合作与市场机会，向具有国际竞争力的基础软件品牌发展。

第三章核心痛点与技术解决方案

3.1 命题约束与问题分析

随着智能体从回答问题转向执行代码修复、功能开发等实际任务，企业需要为其提供能够运行程序、保存工作进度并隔离风险的执行环境。沙箱承担了这一职责，相当于为每个智能体配置一个独立的工作空间。随着智能体数量增加，如何在保障任务正常执行的同时控制资源投入，成为企业规模化部署必须解决的问题。

3.1.1 命题约束

华为提出的“高密部署智能体沙箱引擎”命题，将这一需求具体化：基于指定的 openEuler/Conch + StratoVirt 技术栈运行 OpenClaw，在管理面与容器总内存限制为 16GB、每个沙箱内部规格为 2U8G，即 2 个虚拟 CPU 和 8GB 内存、关闭 Swap 的条件下，提高能够同时运行并完成指定任务的智能体数量。命题要求在有限硬件内存中提高有效并发数，同时保证任务完成率和沙箱隔离。

3.1.2 问题分析

命题需要区分沙箱可见规格与宿主机实际物理内存占用。沙箱内部显示为 8GB 内存，实际运行过程中通常只使用其中一部分。单机可承载的智能体数量主要取决于单个沙箱的实际平均物理内存占用。PI OS 通过降低瞬时资源占用并根据任务阶段动态调度资源，提高高密部署能力。

1. 智能体的执行方式：大模型与工具交替进行

智能体的资源使用特征由执行流程决定。智能体完成任务时，会在大模型（LLM）与三类工具之间交替调用：代码解释器（Code Sandbox）、无状态函数（Stateless Func）和有状态的 MCP Server 工具。以 TravelPlanner 为例，LLM 先生成计划，再调用工具查询交通信息、将计划写入同一 Notebook，最后执行筛选代码并形成出行方案。




图 3-1 智能体任务中 LLM 与工具的交替调用流程

图示表明，LLM 推理与工具执行呈交替关系。LLM 推理期间工具暂停计算，工具执行期间 LLM 等待结果。工具在等待阶段仍保留运行状态，由此产生持续的内存占用。

2. 三类工具的需求彼此异构

不同智能体任务需要保留的状态完全不同。下面是项目测试中六类典型 Agent 负载的资源画像，差异极大：

Agent	Framework	Description	E2E Lat*	Memory	CPU Time
Blackjack	LangChain	Play the Blackjack game.	3.2 s	74 MB	411 ms
Bug fixer	LangChain	Fix the bugs in given code.	36.5 s	95 MB	809 ms
Map reduce	LangChain	Split and summary a document.	56.5 s	199 MB	1.2 s
Shop assistant	Browser-Use	Select the ideal products on a website.	140.7 s	1080 MB	10.3 s
Blog summary	OWL	Collect and summary blogs.	193.1 s	1246 MB	56.8 s
Game design	OpenManus	Implement a html-based game.	107.0 s	1389 MB	7.5 s

图 3-2 典型智能体任务的资源画像

以代码修复任务为例，ls、cat、sed 等命令通常在毫秒级完成，主要使用文件系统和少量内存；wget 等外网访问命令需要网络能力；数据分析程序需要保留较大的内存对象；有状态 MCP 工具需要保留发生变化的内存和寄存器状态。不同工具具有分层、异构的资源需求，现有运行时通常对完整环境进行统一保存和恢复，由此产生额外开销。

项目据此将部署密度问题划分为运行时冗余、资源空转和状态重复三个相互关联的方面，并分别提出对应方案。

3.2 问题 1：运行时冗余

运行时冗余，是指沙箱为了执行具体任务，需要额外维持一套较重的系统环境，而其中相当一部分功能并未被当前任务实际使用。

以代码修复为例，智能体主要执行项目文件读取、代码编辑、测试和结果保存，核心资源是文件系统与少量内存。通用执行环境还会维护后台服务、管理组件和其他系统功能，其中部分组件与当前任务无直接关系，却持续占用内存并增加初始化和状态管理开销。

通用运行组件在每个沙箱中重复加载，固定开销会随实例数量增长，压缩可用于任务执行的内存空间。下图展示单实例在启动和运行阶段的内存构成：Runtime（沙箱运行环境）和 Sandbox（沙箱开销）构成每个实例的固定成本，Waste 表示资源争用或过度配置产生的额外占用。




图 3-3 单实例运行过程中的内存构成

冗余的根源有三层：

1. **Linux 快照与恢复粒度较粗：**CRIU (Checkpoint and Restore in Userspace) 通常对沙箱整体状态进行保存，保存和恢复的数据量较大。
2. **Linux 页置换机制 (kswapd) 采用通用的被动回收策略，**缺少智能体任务语义，可能置换活跃页或遗漏闲置资源。
3. **网络协议栈状态的恢复成本较高：**TCP/UDP 连接、Socket 和网络命名空间的恢复需要频繁调用内核并竞争锁，耗时通常高于普通内存页恢复。

3.3 解决方案 1：运行时扁平化

运行时扁平化将每个智能体的完整运行环境拆分为“轻量运行库 + 系统级共享服务”。系统据此识别工具依赖、状态位置和当前执行所需功能，减少每个沙箱的固定开销。

1. **LibOS (Guest Kernel, 用户态内核)：**在用户态实现文件系统、网络 and 内存管理等应用所需功能，减少对宿主内核共享路径的依赖和锁竞争，降低运行开销。
2. **系统服务 (Services)：**将网络协议栈、文件系统等通用能力从沙箱内部抽离，形成多实例共享服务。沙箱保留任务相关状态，并在访问外网、大模型或文件时按需建立对应的隔离上下文和数据通路，从而降低完整系统组件的重复部署开销。

PI OS 系统架构




图 3-4 PI OS 运行时扁平化系统架构

扁平化架构包含四个关键角色：

1. Std 接口：识别 Tool 启动依赖，确定卸载和恢复所需状态，按状态类型分配内存，作为统一运行时抽象层的语义入口；
2. LibOS：用户态 Guest Kernel，承接文件系统、网络和内存管理等功能，作为精简后的运行内核；
3. Visor：与集群调度器、LLM Proxy 和 Kernel 状态池交互，执行卸载与预取，负责沙箱与宿主机之间的状态传输和协调；
4. Sched / Proxyd / Orchest：管理全局卸载、加载和预取任务，并结合修改后的 Linux 内核完成资源管理和集群侧调度。

3.4 问题 2：资源空转

资源空转，是指工具暂时停止计算后，其运行环境和任务状态仍持续占用资源，其他智能体无法充分利用这部分容量。

智能体按照“LLM 分析与决策、工具执行、结果返回”的顺序循环运行。代码修复任务完成一次测试后，工具会等待 LLM 分析报错并生成下一步指令。等待期间 CPU 计算停止，内存对象和运行上下文仍保持驻留。销毁环境会中断任务状态，完整快照则会增加额外的数据搬运。

下图记录项目测试中的单实例 CPU 与内存使用时序：计算集中在 init、step1 等短时窗口，CPU 峰值为 209.7%；其余时间 CPU 接近 0，内存仍维持在 447.7MB 附近，显示等待阶段存在明显的内存驻留。




图 3-5 单实例 CPU 与内存使用时序

空转体现在两个维度：

1. 工具执行阶段（空间维度）：不同工具具有异构执行需求，统一资源配置会产生分配冗余；
2. LLM 推理阶段（时间维度）：主流方案为保证数据安全和任务连续性，通常保留沙箱全部运行状态，等待期间形成资源闲置。

3.5 解决方案 2：动态资源卸载

动态资源卸载利用智能体执行阶段信息，在工具暂停计算时释放可回收资源，并根据下一次调用的实际需求恢复状态。PI OS 在关闭操作系统 Swap 的条件下显式管理运行状态。该机制由分层状态卸载与按需状态恢复两个子任务协同完成。

3.5.1 分层状态卸载：按状态类型实施保留与恢复

该机制将运行时状态划分为文件、网络、内存、CPU 和寄存器等类型，并分别设置保留与恢复策略，实现闲置资源及时回收。具体包括三个方面：

1. **构建统一运行时抽象层，识别 Agent 状态的类型、用途和生命周期；**
2. **在沙箱接口层完成状态分类与管理，并扩展 Python 运行时，支持对文件、网络、内存、CPU 和寄存器状态分别捕获与卸载；**
3. **扩展 Linux 内核系统服务与沙箱协同机制，依据状态语义分配资源，降低活跃状态被错误置换的概率。**

为支撑该机制，内核侧新增卸载、预加载、激活和释放接口，由系统根据状态语义触发。以 struct agent_park_task 为例，retain_bytes、durable_bytes 和 durable_extents[] 分别记录保留状态量、持久化状态量与持久化区间，io_budget 记录字节数、预计耗时和松弛时间，为内核提供可执行的卸载约束。

3.5.2 按需状态恢复：由状态访问触发加载

每轮执行通常只涉及部分系统功能。按需恢复机制在状态被访问时加载对应组件，降低全量恢复产生的冷启动开销：

1. **语义截获与转发：**对运行时组件修改，截获执行中对文件/网络/内存的访问请求；
2. **恢复流程组装引擎：**访问缺失时，按捕获的请求动态组装恢复流程（如仅恢复文件句柄、重建网络连接、加载内存快照），实现按需加载与重建；
3. **细粒度组件索引：**为每个状态组件（单个文件、网络连接、内存区域）解耦，支持快速定位、独立恢复。




图 3-6 PI OS 动态资源卸载与恢复流程

3.5.3 语义感知的实现路径

1. 运行时触发 (主路径)：在 Guest Kernel 系统库中设置资源访问触发点。wget 调用触发网络挂载，目录操作触发文件系统恢复。资源访问事件直接提供所需状态类型，提高识别精度。
2. 规则感知与预取 (可选增强)：在大模型输出 Token 流时解析 tool call 字段，识别下一步调用并预取所需状态。预取阶段仅加载相关状态，业务操作仍由正式工具调用触发；调用信息不足时，系统转由实际状态访问事件触发恢复。

3.5.4 实测效果

端到端：测试中，PI OS (启用语义卸载) 在约 0.7 秒额外延迟下，将总内存用量降低 78.5%–91.7%；完整沙箱全量快照与恢复 (Full CR) 产生约 6.0 秒延迟，内存用量降低 25%。




图 3-7 不同数据集下的内存占用对比

表 3-1 卸载开销对比 (5 次取中位数)

Benchmark	Full CR 卸载	PI OS 卸载	结果说明
DataSci	7,763.6 ms	118.261 ms	PI OS 加速 64.6 倍
TravelPlanner	7,836.4 ms	16.38 ms	PI OS 共享部分驻留内存

冷启动：单个沙箱约 1.3 ms 完成冷启动，启动时间减少 92.5%。Full CR 在未预取情况下通过缺页异常加载内存，增加约 6.0 秒；加入预取后，额外时间约为 0.7 秒。

受限资源下的系统级对比 (Resident 状态常驻 vs Compact 紧凑模式)：在 8GB 内存、4 CPU 上限、6 秒错峰拉起、DataSci 负载下，两组均完成全部 48 个任务、0 次 OOM：

表 3-2 受限资源下的系统级性能对比

指标	Resident	Compact	提升/变化
QEMU 宿主机平均 CPU (%CPU)	229.7%	465.0%	2.02× (+102.5%)
Guest RSS 峰值 (GiB)	7.59 GiB	7.79 GiB	+0.20 GiB (+2.68%)
系统吞吐量 (batch/s)	0.007072	0.021236	3.003× (+200.3%)
已验证安全并发 (个)	8	≥48	≥6×

3.6 问题 3：状态重复

状态重复，指多个沙箱或同一任务的不同执行轮次，分别保存了内容相同、本可安全复用的状态。

Agent 运行时通常基于**隔离的执行环境**构建，每个实例**独立加载和存储所需状态**。于是：

- 1. 相同的高频复用状态（预训练模型权重、代码依赖库、数据集、配置文件）在不同实例间被重复存储；
- 2. 现有 mmap 等文件级共享机制受执行环境隔离和检查点恢复影响，相同状态在不同实例间仍以独立副本存在，形成重复占用。




图 3-8 传统沙箱实例中的重复状态占用

三个技术挑战：

- 1. **副本冗余**：在隔离环境中如何识别并消除相同状态的重复存储？
- 2. **共享语义丢失**：在状态检查点与恢复过程中如何维持共享语义，避免状态分裂？
- 3. **共享粒度粗**：如何设计细粒度、语义感知的共享机制，匹配智能体多样化的状态类型？

共享边界由内容、版本、访问权限和状态可变性共同确定。任务凭据、私人文件、会话状态和可修改中间结果保留独立副本，以满足隔离和一致性要求。

3.7 解决方案 3：智能内存共享

智能内存共享通过为状态添加语义标识并构建共享状态池，实现跨实例去重以及文件和网络状态复用。系统根据状态用途、生命周期、版本和访问权限确定共享范围，并为私有或可修改状态保留独立副本。

三个层面：

- 1. **多级状态管理机制：**为不同类型智能体运行时提供多级状态标识，支持跨智能体、跨实例、跨阶段的多级共享。
- 2. **系统级共享文件/网络服务：**在保证安全的条件下，构建用户态与系统态协同的共享池，支持文件、网络的调用共享，提高资源使用与读写吞吐。
- 3. **共享语义维持机制：**在状态检查点与恢复过程中，用“引用计数 + 写时复制（Copy-on-Write）”维持共享语义，避免状态分裂，确保共享状态一致。

工程落地细节：

- 1. **语义识别在运行时侧完成：**cat、sed 等命令触发文件系统相关操作，进而按需恢复文件系统；curl 触发网络相关操作；Python 内部通过修改 Python 运行时，在具体语句执行发现状态缺失时按需加载。
- 2. **预取机制在大模型输出 Token 时解析下一步工具调用并提前加载相关状态，以适应执行路径的动态变化。**
- 3. **共享判断的边界：**应同时考虑内容、版本与访问权限。同版本只读依赖文件可作为共享候选；不同任务各自修改的文件、用户凭据、会话数据应保留私有副本；内容相同也不必然允许跨租户共享，需按安全策略限制共享范围。
- 4. **范围限定：**现阶段支持 Python 与 Bash，多语言支持将在后续版本中扩展。

表 3-3 PI OS 关键成果指标

指标	目标值
内存占用减少	≥30%
系统整体吞吐量提升	≥25%
跨实例去重	模型权重 / 依赖库等高复用状态去重

三项方案形成连续的技术路径：运行时扁平化降低基础环境开销并提供状态管理接口；动态资源卸载回收任务等待阶段的闲置资源；智能内存共享消除多个实例间的重复状态。三项方案分别优化固定运行开销、等待阶段驻留开销和跨实例重复占用。

企业部署价值通过规定内存预算下的有效沙箱并发数、任务成功率、完成时间和单任务资源成本进

行评估。项目将在相同硬件、负载与隔离条件下开展对照测试，将技术指标转化为客户可核验的容量收益和成本收益，为市场定位提供依据。

第四章市场与竞争分析

4.1 市场现状

智能体运行基础设施已经形成企业可采购的产品和服务。专业沙箱平台与大型云服务商共同参与市场：E2B 提供面向智能体的独立运行环境，AWS 提供 AgentCore 运行与工具服务，阿里云提供智能体运行和沙箱服务。PI OS 将在现有供给格局中，围绕国产环境适配、资源效率和企业交付建立差异化能力。

1. 企业智能体应用正在扩大，配套运行需求随之增加

德勤《2026 年企业人工智能现状报告》基于对 **24 个国家、3,235 名企业与技术负责人的调查**显示，23% 的受访企业已经至少中等程度地使用智能体，74% 预计在未来两年内达到这一水平。其中，74% 为受访者对未来两年的预期，23% 为当前采用情况，两者之间的差距反映了企业扩大应用的意愿。

PI OS 优先面向已经使用智能体执行代码、处理文件和调用工具的企业。这类应用需要实际的任务执行环境，与沙箱产品的需求直接相关。项目计划从代码修复、功能开发等明确场景切入，围绕真实任务量验证客户需求。

2. 沙箱服务已形成收费模式，细分方向获得资本关注

截至 2026 年 9 月 5 日，E2B 的 Pro 套餐公开价格为 **150 美元/月，资源使用费用另计**；套餐包含最多 100 个同时运行的沙箱，并允许付费增加并发额度。这表明沙箱服务已经形成按照使用规模、运行资源和服务等级收费的商业模式。

融资方面，E2B 于 2025 年 7 月宣布完成 **2,100 万美元 A 轮融资，累计融资达到 3,200 万美元**。该案例表明，智能体执行基础设施已受到专业投资机构关注。融资数据反映资本关注度，营业收入和盈利能力仍需通过经营数据验证。

PI OS 将围绕客户付费理由推进产品化，并在商业化授权明确后，通过部署适配、持续维护和服务支持建立收入来源。

3. 企业仍在增加投入，但成本正在影响应用规模

麦肯锡于 2026 年 8 月发布的全球调查覆盖 **97 个国家的 1,719 名受访者**。调查显示，约 20% 的受访者表示，包含模型调用费用在内的 AI 运营成本已经限制了所在企业的 AI 使用；与此同时，60% 预计企业将在未来一年增加 AI 投入。两项结果共同说明，企业在继续增加 AI 投入的同时，更加重视新增投入带来的业务价值。

这种成本关注也体现在现有产品设计中。AWS AgentCore 已采用按实际 CPU 消耗和会话内存占用计费的方式，在没有 CPU 消耗的等待期间不收取 CPU 费用。由此可见，提高资源使用效率已经成为服务商参与竞争的一个方向。

PI OS 的商业价值应以客户实际账本衡量：在相同任务质量与服务要求下，减少资源投入或让已有服务器完成更多任务。沙箱优化对应整体 AI 成本中的执行环境部分，项目将单独核算其资源和运维改善幅度。

4. 企业需求存在差异，为适配与交付服务提供切入点

德勤报告显示，85% 的受访企业预计需要定制智能体，以适应自身业务需求。调查结果说明，企业应用需要结合业务流程、工具组合和运行环境进行适配。

阿里云等厂商已提供自定义镜像、代码执行、浏览器操作和存储接入等能力，适配与集成已经成为市场基础能力。PI OS 将把国产操作系统适配、有限资源下的任务承载能力和交付服务作为可验证的差异化方向。

企业采用、公开收费和资本参与等信号表明，智能体执行基础设施已经进入商业化阶段。PI OS 将通过客户试点验证付费转化，当前重点是识别具有明确任务规模、部署要求和采购预算的客户。

4.2 市场前景

智能体运行基础软件的市场需求正在从开发工具延伸到企业业务中的持续运行服务。近期研究与公开案例表明，企业希望让智能体承担更完整的工作流程，规模化应用对部署效率、运行成本和可靠性提出了更高要求。PI OS 的近期市场机会集中在已经开展试点并扩大任务规模的企业，这些客户需要高效执行环境和专业交付服务。

4.2.1 市场趋势和驱动因素

1. 智能体从单项工具走向业务流程，运行服务需求有望持续扩大

德勤于 2026 年 8 月 12 日发布的调查显示，74% 的受访管理者预计，未来四年内，所在企业近一半的业务流程将围绕智能体重新设计；但目前只有 15% 的受访企业已经规模化采用跨职能、多智能体协同。这项调查覆盖美国五个行业的 501 名管理者，参与企业均已至少开展智能体试点，数据反映了已有应用基础企业的扩展预期。

企业后续需求包括多任务稳定运行、现有业务系统连接和持续增长的工作量管理。PI OS 可优先面向已经开展试点、正在扩大使用范围的客户，通过任务承载能力和交付质量争取采购机会。

2. AI 基础设施投入增长，为配套运行软件提供发展空间

Gartner 于 2026 年 8 月 10 日发布预测，全球 AI 优化型基础设施即服务（IaaS）支出将在 2026 年达到 422.76 亿美元，同比增长 96.4%；2027 年预计进一步达到 661.43 亿美元。预测数据显示，支撑 AI 实际运行的基础设施仍处于较快投入阶段。

表 4-1 全球 AI 优化型 IaaS 支出及预测

年份	支出规模（亿美元）	同比增速	数据性质
2025 年	215.29	180.0%	报告列示的基期值
2026 年	422.76	96.4%	机构预测
2027 年	661.43	56.5%	机构预测

上述规模覆盖模型训练、推理等基础设施支出，统计口径大于智能体沙箱市场。其对 PI OS 的参考价值在于：企业持续投入 AI 基础设施，将带动资源效率优化、部署维护和配套软件服务需求。

3. 投资关注点将更加重视使用成本与实际回报

IDC 于 2026 年 8 月 28 日发布的研究解读指出，相关调查中，67% 的企业在过去一年内的智能体支出超过预算 10% 以上。该统计覆盖智能体整体支出，其中沙箱对应执行环境部分的成本，数据反映了规模化应用中的成本管理压力。

据此，PI OS 的商业化重点应落在能够核算的客户收益上：在相同任务质量和响应要求下，是否能够减少资源投入、延缓扩容，或提高已有服务器的任务完成量。后续报价与续约应建立在实际效果和服务质量上。

4.2.2 智能体运行服务的应用领域广泛

以下案例来自公开资料，用于说明行业应用方向；PI OS 的实际客户和交付能力以项目合同与测试记录为准。

1. 软件研发与自动化测试

代码修复、功能开发和测试执行与 PI OS 的企业命题直接对应，是项目最适合优先进入的场景。E2B 于 2026 年 7 月公布的 Devin Outposts 集成方案，支持开发任务在企业可控制的云环境中执行，并访问私有代码仓库和内部服务，体现了研发智能体对执行环境与企业系统接入的需求。

PI OS 可围绕企业研发团队和代码智能体平台，验证并发任务承载、任务完成质量及部署维护成本，形成首批可复制的交付案例。

2. 数据分析与研究报告生成

数据分析智能体需要执行程序、处理文件并生成可使用的结果。E2B 于 2026 年 5 月披露的 Genspark 案例，展示了沙箱在数据分析、研究和报告生成等多步骤任务中的应用。

数据分析场景可作为 PI OS 在代码任务之外的延伸方向，面向数据分析平台和企业内部研究工具提供运行支持，重点验证文件处理、较长任务运行和多用户使用的稳定性。

3. 企业办公与业务流程自动化

人力资源、销售支持和文档处理等工作，往往需要连接多个系统并执行重复操作。E2B 于 2026 年

2 月披露，Gumloop 已持续使用其代码执行服务两年多，应用覆盖智能体工具调用、自定义流程和系统集成。

这类应用需要持续的环境维护、版本适配和故障支持，可形成部署后的年度服务需求。PI OS 可在基础产品稳定后，与业务应用开发商合作进入此类市场。

4. 金融与保险业务辅助

金融保险领域存在模型计算、表格处理和业务材料准备等执行需求。E2B 于 **2026 年 8 月 5 日披露**，Effective AI 利用沙箱支持保险产品相关工作，月用户会话超过 **1 万次**。该数字来自厂商公开案例，项目评估时将结合独立客户数据复核。

金融保险领域对数据隔离、权限和过程记录提出较高要求。PI OS 将在完成相应验证后，通过行业合作伙伴进入辅助分析与材料处理场景，创业初期的服务范围限定在辅助性任务。

5. 模型评测与科研实验

模型评测需要反复执行大量任务，并保证不同实验之间互不影响。E2B 于 **2026 年 9 月 3 日披露**，Paper Instruments 使用其沙箱运行数千个并发实验任务，每个任务保留独立的文件与执行状态。

批量评测工作负载与高密部署具有较强关联。PI OS 可面向模型研发团队和科研机构，探索批量评测服务，重点验证单位资源能够完成的实验数量，以及实验环境的一致性。

6. 工业工程与制造业研发

智能体的应用也在向专业工程领域延伸。西门子于 **2026 年 4 月 20 日发布** Eigen Engineering Agent，并披露该产品此前已在 **19 个国家、超过 100 家客户**中试点，支持工业自动化工程任务。

对 PI OS 而言，潜在切入点是工程代码、测试脚本和研发辅助任务的执行环境。该领域可作为中长期拓展方向，需要结合专业软件适配和行业合作逐步推进。

PI OS 的市场拓展分为三个阶段：首阶段聚焦代码任务，第二阶段扩展数据分析与批量评测，第三阶段通过合作进入专业行业。项目收入将以客户试点收益、付费转化和可复制交付为依据。

4.3 目标市场

PI OS 面向需要批量运行人工智能智能体的企业和科研机构，提供智能体执行环境及配套部署服务。智能体执行环境为 AI 提供代码运行、程序测试和数据处理所需的隔离空间。PI OS 在满足任务质量与安全要求的前提下，提高客户现有服务器的任务承载能力，降低智能体规模化应用的运行成本。

麦肯锡于 2026 年 8 月发布的全球调查显示，在年营收超过 10 亿美元的大型企业受访者中，报告所在企业正在规模化部署智能体的比例由上年的 27% 上升至 40%；较小企业的对应比例为 22%。智能体规模化应用较集中的职能包括信息技术、知识管理和软件工程。该调查覆盖 97 个国家的 1,719 名受访者，用于反映全球样本趋势；中国市场情况仍需结合本地客户验证。

基于上述需求分布，PI OS 将首先进入软件研发和智能体开发场景，优先服务已经拥有实际任务、

部署预算和内部技术团队的客户，再逐步拓展科研平台及行业解决方案市场。

4.3.1 PI OS 具有以下重要特点

1. 面向智能体实际工作的运行需求

PI OS 聚焦智能体程序执行、工具调用和文件处理，为客户现有大模型和业务系统补充执行环境。客户可以在保留现有系统架构的基础上评估和接入 PI OS。

该定位聚焦客户已有工作流程，通过真实任务检验产品价值，并缩小客户的系统改造范围。

2. 以现有设备的使用效率创造价值

PI OS 围绕运行时扁平化、动态资源卸载和智能内存共享开展研发，商业目标是减少运行环境中的重复占用和无效等待，提高同等设备条件下的任务承载能力。

客户价值体现在减少任务排队、延缓服务器扩容和降低合格任务的综合成本。上述收益将通过客户实际环境中的对照测试确认。

3. 面向国产运行环境与企业部署需求

项目以华为命题指定的国产运行环境为适配方向，规划提供客户自有服务器或云环境中的部署、调试和维护服务，支持客户结合自身的系统配置与管理要求使用产品。

企业对智能体的需求具有明显的业务差异。德勤 2026 年 1 月发布的调查显示，85% 的受访企业预计会根据自身业务需求定制智能体。该调查于 2025 年 8—9 月开展，覆盖 24 个国家的 3,235 名企业与信息技术负责人。调查结果支持项目对企业适配服务的关注，沙箱软件采购需求将通过客户访谈和试点进一步确认。

4.3.2 PI OS 现阶段目标市场

PI OS 的市场进入顺序为企业场景、科研验证和渠道合作。

表 4-2 PI OS 目标客户与市场进入顺序

目标客户	主要应用场景	主要采购决策方	市场进入安排
智能体应用开发企业、AI 编程平台	代码修复、功能开发、自动测试等任务的批量执行	技术负责人、研发平台负责人	优先争取付费验证与部署项目
企业内部研发中心	在现有服务器上运行内部研发智能体	研发管理部门、信息化部门	以具体部门或项目试点切入
高校实验室、研究所及模型评测团队	智能体实验、代码能力评测、重复任务验证	课题负责人、科研平台管理部门	形成可复核案例，按项目预算采购
云服务商、软件厂商及系统集成商	将执行引擎纳入自身产品或行业方案	产品部门、解决方案部门	在产品标准化后拓展合作

1. 企业软件研发与智能体平台市场

这类客户直接面对智能体任务的运行费用、任务完成速度和服务稳定性，是项目优先争取的商业客户。项目计划从代码修复、自动测试等边界清晰的任务切入，用客户已有系统与 PI OS 方案完成同一批任务，比较任务完成情况、设备占用和维护投入。

对于已经存在运行压力的客户，采购理由可以具体落实到“是否需要增加服务器”“任务是否能够按时完成”，有利于形成明确的预算依据。

2. 高校、研究所和企业研究院市场

科研客户适合开展新方案验证、重复实验和性能评测。PI OS 计划提供研究环境部署、任务运行支持和实验数据整理服务，帮助科研团队减少环境配置及重复运维工作。

目标客户包括拥有真实计算任务和项目经费的实验室、研究团队及公共平台。科研合作、免费试用与实际采购收入分别统计。

3. 云服务与行业解决方案市场

完成标准化交付后，PI OS 计划向云服务商和系统集成商提供运行引擎集成、环境适配及维护支持。合作方负责上层应用和客户服务，PI OS 聚焦智能体执行环节，并借助已有销售渠道扩大覆盖范围。

现阶段市场测算以可触达客户、试点转化率和实际合同金额为基础，并按照 PI OS 的可交付范围核算服务市场。

4.4 商业模式

4.4.1 商业模式概述

PI OS 采用“部署适配服务 + 年度软件与维护服务”的企业级商业模式，相关业务将在成果商用授权和产品验收完成后启动。

项目初期优先利用客户已有服务器和云资源开展交付，由客户承担自身计算资源费用，PI OS 收取需求分析、安装部署、系统适配和持续维护等费用。对于具备合法商业许可条件的产品版本，再提供年度软件订阅。

该模式将初期资金集中用于产品完善和客户交付，并控制自建大规模算力设施的资金投入。标准化程度提高后，业务将由一次性项目交付逐步转向可重复部署的软件产品和持续服务。

客户转化流程包括：

需求确认 → 小范围验证 → 验收采购 → 正式部署 → 年度续费与扩容。

其中，小范围验证重点回答三个问题：能否完成客户任务、综合成本是否具有改善空间、接入与维护投入是否可以接受。

4.4.2 客户细分

1. 智能体应用开发企业

这类客户将智能体能力作为对外产品或服务，需要稳定承接用户任务。其主要关注运行费用、任务完成速度，以及业务增长后能否平稳扩容。

PI OS 提供执行环境接入、部署调优和持续支持，帮助客户将研发资源更多投入上层产品。

2. 企业内部平台建设部门

这类客户为企业内部的多个团队建设统一研发或智能体平台，更关注系统兼容性、运行可控性和长期服务保障。

PI OS 按照客户已有设备、网络和运维流程开展部署，并提供配置文档、故障处理方式和升级安排。

3. 科研与评测机构

科研与评测机构重视环境可复现、任务批量执行和实验结果可追溯。项目按照课题或平台建设需求提供部署与技术支持，商业转化以合同金额和持续采购为主要指标。

4. 产品集成与渠道客户

这类客户购买的是能够嵌入自身方案的产品能力及支持服务。合作重点包括版本兼容、交付责任、维护边界及终端客户支持机制，收入方式通过具体合作协议确定。

4.4.3 合作伙伴和资源

项目的现有研究基础与华为、天津大学开展的“Agentic 运行时分层状态卸载与共享技术合作项目”相关。已有合作材料能够支持企业需求来源和研究方向真实性，为项目开展命题适配、方案完善和工程验证提供基础。

商业化过程中，项目将重点整合三类资源：

1. 研究与工程资源：将已有代码、测试方法和技术积累转化为可安装、可验证、可维护的产品。
2. 场景与验证资源：争取具有真实任务的企业和科研机构参与试点，形成经客户确认的交付案例。
3. 生态与渠道资源：在产品成熟后，与国产操作系统生态、云服务商和系统集成商探索适配及联合交付。

现有科研合作主体与未来创业经营主体分别管理。合同项下成果的使用、许可及对外展示须遵守既有权属和保密约定；科研合作材料用于说明技术来源，客户采购和营业收入以商业合同为准。

4.4.4 可持续发展和扩展性

1. 将重复交付内容产品化

项目将安装配置、环境检查、常见任务接入和故障诊断整理为标准工具与文档，减少每个客户的重复开发工作。通用需求进入标准版本，特殊需求单独评估和收费，以控制定制项目对研发资源的占用。

2. 通过持续服务形成续费收入

智能体框架、业务任务和客户环境会持续变化。项目围绕版本升级、兼容性维护、运行诊断和容量规划提供年度服务，使收入来源由一次性交付逐步延伸至持续维护。

3. 从单点试用扩展至多团队部署

市场拓展从一个可验证场景开始，客户确认效果后，再扩展至其他项目组、服务器或业务部门。客户内部扩展能够降低重复获客成本，交付范围根据试点稳定程度逐步扩大。

4. 以经营质量衡量增长

项目将持续跟踪付费验证转化率、交付周期、单客户服务投入、续费率和毛利情况。增长质量由客户数量、同类项目复制效率和单位研发人力产出共同衡量。

4.4.5 收费模式

PI OS 分阶段提供以下收费方式：

1. 验证与部署服务

针对需求明确的客户，按约定任务开展验证，交付测试结果、适配说明和部署方案。涉及客户专有系统改造的工作另行报价，免费验证的任务范围和周期在协议中明确。

2. 企业年度订阅

在相关成果获得商业使用授权后，按产品版本、管理规模和服务等级提供年度订阅。客户使用自有计算资源，软件订阅费用与服务器、云资源及大模型调用费用分别列示。

3. 专项适配与维护

对于特殊系统、专用工具和非标准业务流程，按项目工作范围收费。年度合同之外的重大改造，通过新增服务订单确定。

4. 后续托管服务

计量、稳定性和单位成本完成验证后，项目将评估托管式服务，并采用资源包或按量计费。当前阶段聚焦部署、适配和年度订阅服务。

4.4.6 收费规则

PI OS 的统一销售价格将在付费试点后确定。当前计费规则以交付成本、客户规模和试点结果为依据。

表 4-3 PI OS 拟定收费规则

收费项目	计费单位	主要交付内容	费用边界
场景验证服务	项目	需求确认、基线测试、方案验证、结果报告	事先明确任务范围、周期与验收条件
部署与系统适配	项目	安装配置、接口适配、上线支持、使用培训	超出约定范围的新增开发单独报价
企业软件订阅	年度基础费 + 约定管理规模	已获商业授权的软件版本及约定功能	管理规模按服务器节点等明确口径约定
运维与升级服务	年度	故障支持、版本升级、兼容性维护	已包含在订阅中的服务不重复收费
托管运行服务	资源包或实际用量	运行环境及配套服务	后续推出，分别列明计算、存储等计费项

定价将同时考虑交付成本和客户获得的价值。客户价值通过同等任务质量要求下的综合成本比较确认，成本范围包括计算资源、软件服务、部署摊销、运维以及失败重试等相关投入，各项性能提升按照其实际影响范围计入成本测算。

项目也将提供可核对的用量与服务记录，明确免费验证范围、订阅期限、扩容方式及超额处理规则，降低客户对后续费用不确定性的顾虑。

4.5 竞争分析

4.5.1 世界竞争环境分析

智能体执行基础设施已经出现专业沙箱厂商与大型云平台共同参与的竞争格局。专业厂商主要围绕开发者接入和执行环境提供产品，大型云平台则将执行能力与模型、身份管理及运行管理等服务组合交付。

E2B 已提供云沙箱和客户自有环境部署选项；Daytona 的虚拟机沙箱支持保留内存状态的暂停与恢复；AWS AgentCore 则提供智能体运行环境及配套工具服务。上述能力已经成为智能体执行基础设施的常见配置，竞争差异将更多体现在资源效率、适配成本和交付质量。

PI OS 聚焦特定国产运行环境和真实任务负载，通过设备使用效率、部署适配和持续服务参与竞争。

本次调研未获得能够直接比较上述厂商沙箱业务市场份额的统一权威数据，因此竞争判断以公开产品能力、收费方式及交付条件为依据。

4.5.2 国内竞争环境分析

1. 国内云平台已进入智能体执行市场

阿里云 FC 云沙箱已经公开不同运行状态下的计费规则；百度智能云 AX 提供代码执行、浏览器操

作等智能体运行场景及配套管理能力。国内市场已经形成云平台产品供给，PI OS 将围绕自有部署、国产环境适配和专项运行优化建立差异化。

对已经使用相应云平台的客户而言，继续采购同一体系内的服务可能更便于接入和管理。PI OS 将优先寻找具有自有部署、指定国产环境或专项运行优化需求的客户。

2. 资源节约正在成为产品的共同竞争方向

阿里云 FC 云沙箱的公开规则区分活跃、浅休眠和深休眠状态：浅休眠不收取 CPU 费用，深休眠不收取 CPU 和内存费用，但仍存在磁盘费用。AWS AgentCore 的运行环境也区分实际 CPU 消耗和内存消耗，等待期间仍可能产生内存费用。

PI OS 的竞争验证将比较同一批任务的综合投入、资源回收等待时间、任务失败率和维护成本。

3. 收费竞争已经具有公开参照

截至 2026 年 9 月 5 日，部分厂商公布的计算资源单价如下。

表 4-4 相关产品公开计费参照

产品	CPU 单价	内存单价	适用说明
E2B Hobby / Pro	0.0504 美元 / vCPU·小时	0.0162 美元 / GiB·小时	由官方秒单价换算；Pro 另有 150 美元 / 月套餐费。 官方价格
Daytona 通用计算	0.0504 美元 / vCPU·小时	0.0162 美元 / GiB·小时	按秒计费，存储等项目另计。官方价格
AWS AgentCore Runtime microVMs	0.0895 美元 / vCPU·小时	0.00945 美元 / GB·小时	CPU 按实际活跃消耗计费，内存按其官方规则计 量。官方价格
阿里云 FC 云沙箱 Std	0.078 元 / vCPU· 小时	0.039 元 / GiB· 小时	中国内地邀测按量单价，不能视为面向全部客户正 式开放的统一价格。官方价格

注：上述价格按各产品公开的币种、资源单位、运行状态和服务范围列示。完整价格比较还需核对存储、网络、模型调用、套餐及其他费用。

以 E2B 公布的资源价格计算，配置为 2 vCPU、8 GiB 内存的运行环境，连续运行 1 小时的 CPU 与内存费用为：

$$2 \times 0.0504 + 8 \times 0.0162 = \mathbf{0.2304 \text{ 美元。}}$$

该算例包含 CPU 与内存资源费用。PI OS 的售价和利润测算还需纳入软件、部署、运维、网络、存储和模型调用等成本。计算依据：E2B 官方价格

公开价格为客户替代方案提供参照。PI OS 将以完整交付成本和客户任务成本参与竞争。

4. 市场拓展与服务能力同样重要

国内竞争同时取决于产品性能、采购便利性、接入速度和持续支持。PI OS 将通过范围明确的付费验证、标准化部署和可追溯的服务记录建立客户信任，并逐步扩大应用范围。

4.5.3 竞争对手

PI OS 的竞争对象既包括商业沙箱平台，也包括客户基于现有技术自行建设的执行环境。各类方案的交付范围存在差异，比较时需要结合客户原有系统和采购需求。

表 4-5 主要竞争方案与 PI OS 的进入方向

竞争方案	已公开的产品特点	PI OS 拟争取的客户需求
E2B	提供智能体沙箱、自定义环境及自有环境部署选项。产品说明	指定国产环境中的适配、实际任务效率和本地交付支持
Daytona	提供沙箱运行环境，虚拟机类型支持保留内存状态的暂停与恢复。官方文档	对任务运行成本和部署条件有专项要求的场景
AWS AgentCore	提供运行环境、代码执行等服务，采用相应资源计费规则。官方说明	希望围绕既有国产基础设施建设执行能力的客户
阿里云 FC 云沙箱	区分运行与休眠状态，配套云端资源管理和计费。官方文档	自有部署及非标准环境中的适配与优化需求
百度智能云 AX	覆盖代码执行、浏览器操作等场景及运行管理。产品说明	已有上层智能体应用、主要需要执行环节支持的客户
企业自建方案	自行选择虚拟化、容器或开源组件，并承担集成和维护责任	希望减少自研维护投入、获得明确交付责任的客户

PI OS 当前已经完成相关代码开发，产品化交付、指定环境适配和商业验证将通过后续验收确认。项目现阶段的优势包括研究积累、命题匹配方向和专项优化能力，商业领先程度将在客户交付和付费验证后评估。

后续竞争验证将围绕四项指标展开：

- 1. 任务效果：同一批任务的成功完成情况是否保持稳定。
- 2. 综合成本：纳入资源、软件及运维投入后，是否具有采购价值。
- 3. 接入成本：客户需要改造多少现有系统，多久能够投入使用。
- 4. 持续保障：升级、故障恢复及问题处理能否形成稳定交付能力。

4.5.4 SWOT 分析

表 4-6 PI OS SWOT 分析

类型	主要判断	对应策略
优势 S	具有企业命题和相关研究基础；已有代码开发积累；聚焦智能体执行效率这一具体问题	以真实任务形成可复核成果，将研究积累转化为标准产品
劣势 W	商业产品成熟度、付费客户及续费表现尚待验证；早期交付可能依赖定制；成果商用存在授权前提	完成授权与产品验收，控制定制范围，优先形成少量高质量付费案例

类型	主要判断	对应策略
机会 O	企业正在扩大智能体应用，特定运行环境和业务流程存在适配需求	优先进入软件研发与评测场景，再扩展至平台和渠道合作
威胁 T	云平台与专业厂商持续完善产品，客户也可自建；功能竞争和价格竞争可能压缩利润空间	以任务成本、接入效率及持续服务建立差异，避免仅依赖单一功能竞争

SW 分析：优势与劣势

PI OS 聚焦明确的企业问题，已有代码和研究基础能够支持后续验证。商业化工作将这些积累转化为客户能够采购、部署和持续使用的产品。

项目当前重点包括明确成果使用权限、完善标准交付、获得付费验证，并形成真实的成本与续费数据。同类客户以较低新增投入完成部署后，技术积累将逐步转化为可持续的经营优势。

OT 分析：机会与威胁

智能体应用增长为执行基础设施带来需求，也吸引大型云平台和专业厂商持续投入。PI OS 的市场机会来自需求具体、价值可验证的细分领域，主要威胁包括产品同质化、客户沿用现有平台和客户自建方案。

项目从一个明确场景起步，在效果确认后复制到相似客户。长期竞争力由客户持续付费的运行效率、可靠交付和服务能力构成。

第五章运营分析

PI OS 的运营目标，是将已经完成的代码开发成果转化为可部署、可验收、可持续维护的企业级产品。项目将围绕“质量可靠、交付可控、成本清晰、责任明确”建立运营机制，先完成企业命题验证，再推进客户试点与商业化交付。

德勤于 2026 年 8 月发布的调查显示，67% 的受访管理者认为智能体集成成本过高、过程复杂，70% 表示对智能体的信任与治理能力存在顾虑。该调查于 2026 年 4—6 月开展，覆盖美国五个行业的 501 名管理者，参与企业均已至少开展智能体试点。上述结果反映出，企业落地智能体不仅需要技术产品，还需要配套的部署、质量和服务管理。

以下质量制度与组织安排为 PI OS 拟实施的运营方案，创业后的部门和岗位根据实际业务逐步建立。

5.1 质量评审

PI OS 的质量评审对象包括运行引擎、系统适配代码、部署工具、测试结果和交付文档。评审重点是：能否满足企业指定条件、正确完成任务，以及客户接入后能否稳定使用。

项目拟建立“开发自检、交叉复核、场景验收”三级质量机制。开发人员负责模块自检，其他成员复核关键功能和实验结果，最终依据企业命题或客户约定完成场景验收。影响任务正确性、资源限制和数据隔离的重大问题未解决前，不进入正式交付。



图 5-1 三级质量评审流程

按照华为命题的技术评价要求，PI OS 的质量工作安排见表 5-1。

表 5-1 企业命题技术评价与质量工作对应关系

技术评价项	权重	PI OS 质量工作重点	主要验收材料
功能完整性	35%	指定环境运行、任务执行、资源管理及异常处理	功能测试记录、任务结果、演示材料
性能满足度	30%	在规定资源条件下验证有效并发、完成时间和稳定性	对照实验、资源记录、统计结果
创新性和代码质量	25%	验证三项方案的实际贡献，检查代码结构与维护能力	分项实验、代码审查和版本记录
文档完整性	10%	确保产品能够构建、部署、复现和排障	部署手册、测试报告、维护文档

5.1.1 功能可行性

1. 命题条件符合性

质量评审首先检查企业指定的技术环境、资源限制和任务要求，以 openEuler/Conch + StratoVirt 代码和镜像为准，核对管理面与全部容器总内存不超过 16GB、每个沙箱内部可见规格为 2U8G、关闭 Swap 等条件是否落实。

所有辅助管理和状态处理组件的资源开销均纳入约定计量范围。内部研究环境的测试结果与企业指定环境的验收结果分别记录。

2. 任务结果正确性

代码修复任务需要保留原始问题、修改内容和测试结果；功能开发任务需事先明确功能要求与验收用例。任务是否成功，以实际执行结果为依据，而非仅依据智能体生成的“完成说明”。

Anthropic 于 2026 年 1 月发布的智能体评估实践强调，应检查环境中的最终结果，并通过重复试验观察表现的稳定性。PI OS 拟据此将任务结果、执行过程与异常记录一并纳入评审。

3. 性能与资源计量

性能评审同时记录有效并发数量、任务成功率、完成时间、内存峰值和失败原因。其中，有效并发是指在同一时间窗口内实际运行并满足任务要求的独立沙箱数量，不能用累计任务数量代替。

对照实验固定硬件、模型、任务、软件版本和超时条件，并保留重复测试结果。Anthropic 于 2026 年 2 月披露，在其 Terminal-Bench 2.0 内部实验中，仅调整资源配置（其余条件不变），最高与最低配置下的任务成功率相差 6 个百分点。这说明资源条件本身可能显著影响结果，必须与性能数据同时报告。

4. 三项方案贡献验证

运行时扁平化、动态资源卸载和智能内存共享分别开展验证，再测试组合效果。

运行时扁平化重点检查基础运行开销是否减少；动态资源卸载同时检查释放效果和恢复等待；智能内存共享同时检查重复占用变化和任务隔离情况。通过逐项开启、关闭相关功能，区分各项方案带来的收益与额外成本。

5. 安全与隔离

评审覆盖任务之间的文件访问、权限边界、网络访问和凭据使用，检查一个任务是否可能读取或修改其他任务的数据。

共享机制拟优先面向经许可的公共只读内容，客户私有文件、凭据和可写状态保持隔离。沙箱负责执行环境的隔离，涉及发送信息、修改业务数据等操作的授权，由上层业务系统与客户管理流程共同控制。

6. 异常处理与恢复

测试覆盖模型调用超时、任务取消、状态保存失败、恢复失败、进程退出和网络中断等情形。每类异常应具有明确的记录、提示及处理方式。

对于可能产生外部影响的操作，恢复前检查其是否已经执行，防止重复提交。故障处理优先控制影响范围、保留必要记录，再依据预案恢复任务或交由人工处理。

7. 稳定性与版本发布

产品发布前开展持续运行、批量任务和反复启停测试，检查资源是否能够正常回收。涉及资源管理、恢复或共享机制的修改，必须重新执行相关回归测试。

拟采用小范围上线方式，先在受控环境或有限任务中观察新版本表现，确认无明显退化后再扩大使用范围。每次发布保留版本记录与回退方案。

8. 客户使用价值

客户验收除技术指标外，还应检查部署工作量、维护投入和任务综合成本。

质量评审将分别呈现执行基础设施、模型调用、存储网络及运维成本，判断性能改善是否能够转化为客户可获得的经济收益。客户是否继续采购，以其真实使用结果和预算决策为依据。

5.1.2 文档标准性

PI OS 拟将文档作为产品交付的一部分，与代码版本同步管理。文档质量主要从完整性、正确性和一致性三个方面评审。

1. 完整性

交付资料应覆盖环境要求、安装部署、使用接口、测试复现、故障处理和版本升级等内容。

部署文档说明所需设备、软件版本及配置步骤；测试文档列明任务、条件、指标定义与结果；维护文档提供常见问题、已知限制和回退方法，使接收方能够在约定支持范围内完成操作。

2. 正确性

关键命令、配置步骤和测试流程由非原作者成员按照文档复核。图表标明数据来源、单位、样本数量和测试条件，计算结果能够追溯至原始记录。

实测结果、测算结果和后续目标分别标注，避免把预期效果写成已经完成的成果。

3. 一致性

代码、镜像、配置、测试报告和使用手册使用统一版本标识。接口或配置发生变化时，同步更新相关资料，避免客户依据旧文档部署新版本。

面向企业验收、赛事展示和客户交流的材料统一采用经确认的数据口径，并按授权范围处理客户信息及合作资料。

5.2 组织管理

5.2.1 创业初期

创业初期以完成命题验证、形成标准交付包和开展客户试点为主要任务，采用项目负责人统筹、职能小组协作的管理方式。项目已完成代码开发，现阶段资源将重点投入适配验证、质量完善和交付准备。

1. 按里程碑推进工作

将工作划分为需求确认、环境适配、质量验证、试点交付和问题复盘等阶段。每个阶段明确负责人、交付物、资源预算和验收条件，完成情况以代码、记录 and 实际结果确认。

拟每周检查进度与阻塞问题，每月复核预算、质量和客户反馈，及时调整优先级。



图 5-2 创业初期里程碑推进安排

2. 明确客户交付范围

客户试点开始前，确认任务类型、运行环境、测试周期、验收指标和双方责任。新增需求先评估工作量及维护成本，再决定进入标准版本、单独报价或暂缓实施。

通过明确交付范围，控制免费验证和定制开发的投入，减少项目延期与重复返工。

3. 分级处理运行问题

影响大范围任务或涉及数据隔离的问题，优先限制影响并升级处理；影响部分功能的问题，提供临时方案并安排修复；一般体验问题进入版本计划。

具体服务时段和响应承诺根据实际人员配置与合同确定，不在尚未建立保障能力时承诺全天候服务。

4. 控制资金与资源投入

初期优先使用经授权的现有测试资源和客户部署环境，避免在需求尚未验证前大量采购设备。商业项目分别记录人工、云资源和外部服务支出，结合验收与付款节点安排投入。

科研经费、创业经营资金和客户款项按各自用途分别管理，不将科研合作合同金额直接视为创业主体可支配现金。

5.2.2 创业成长期

当试点能够转化为重复采购、交付流程逐步稳定后，项目进入以标准化和复制效率为重点的成长期。

1. 推进产品与交付分工

研发侧维护通用产品、稳定版本和自动化测试；交付侧负责安装、接入和问题反馈。可复用的客户需求进入产品规划，单个客户的特殊需求单独管理。

通过减少重复开发，使新增客户数量增长不完全依赖研发人员同比增加。

2. 建立运营指标记录

运营评价同时关注技术表现、客户转化和资金回收，拟采用以下指标。

表 5-2 PI OS 拟跟踪的核心运营指标

指标	统计口径	管理用途
有效任务成功率	满足预定验收条件的任务数占全部提交任务数的比例，另列失败原因	判断产品是否稳定可用
试点付费转化率	已结束试点中转为付费合同的项目比例	检验客户需求与采购意愿
首次交付周期	从需求和环境确认至首次验收的时间	衡量接入效率
单项目直接交付成本	实际交付人工、计算资源及外部服务等成本	识别低效定制与利润压力
客户续费率	统计期内到期客户中完成续费的比例	判断持续服务价值
合同回款情况	按合同付款节点记录应收、实收与逾期情况	控制现金流风险

3. 按业务瓶颈补充人员

人员扩充优先解决已经出现的交付瓶颈，例如测试积压、兼容问题或客户支持负担，而不是先建立完整部门再寻找业务。

新增岗位同时评估稳定工作量、收入支撑和现金储备，使组织规模与实际经营能力匹配。

4. 逐步拓展合作交付

在产品接口、维护责任和成果授权明确后，探索与软件厂商、云服务商及系统集成商合作。合作前确认客户归属、支持边界、服务费用及问题升级机制，减少多方交付中的责任不清。

5.2.3 创业成熟期

当产品形成持续收入、稳定客户和可复制交付能力后，逐步建立专业化经营体系。

经营管理重点由单个项目推进转向产品生命周期、客户留存、成本效率和长期研发投入。公司治理及经营岗位根据实际主体和业务规模设置，必要时引入具有企业软件经营与交付经验的管理人员。

成熟期拟重点完善以下机制：

1. 版本生命周期管理：明确版本支持期限、升级路径及停止维护安排。
2. 服务质量管理：持续分析故障原因、恢复效果和客户反馈，减少同类问题反复发生。
3. 经营预算管理：区分产品研发投入、客户交付成本和市场费用，定期检查投入产出。
4. 客户与渠道管理：降低对单一客户、单一渠道或单一关键人员的依赖。
5. 人才接续管理：通过文档、培训和岗位备份，保障人员变化后业务仍能持续运行。

5.3 人事管理

PI OS 的人员管理坚持职责明确、能力互补和贡献可追溯。参赛学生、科研合作人员与未来经营团队的身份分别记录，岗位规划不等同于现有劳动关系或任职事实。

企业命题组评审将“团队协作”列为 20 分评价项，并明确从团队结构、团队资源与团队贡献等方面考察。因此，团队建设既关注后续经营能力，也重视学生在需求调研、工程验证和项目协作中的真实成长。

5.3.1 创业初期管理架构

初期拟采用精简的职能协作架构，由项目负责人统筹，下设产品研发、质量验证、交付运营和商务综合四类职责。成员可以根据能力兼任，但关键开发成果和验收结论实行交叉复核。



图 5-3 创业初期拟定管理架构

1. 以实际任务配置职责

岗位安排依据成员能够独立完成的工作确定。研发职责对应代码与维护记录，质量职责对应测试与复核记录，商务职责对应需求访谈及客户沟通材料。

团队不以职位名称替代实际能力，也不将材料整理工作直接等同于底层技术研发贡献。

2. 建立关键岗位备份

关键模块拟同时指定主要负责人和备份人员，定期整理部署方法、常见问题和未完成事项，降低课程安排、毕业或成员流动对项目的影响。

客户环境访问权限、账号及项目资料统一登记；职责变化时同步办理资料和权限交接。

3. 将培养与交付结合

新成员通过环境搭建、测试复现、文档完善和小范围问题修复逐步参与项目。关键修改经评审后合入，避免在缺乏指导和验证的情况下直接影响客户使用。

个人贡献由任务成果、复核质量及协作记录共同体现，不以代码行数或投入时长作为唯一评价标准。

5.3.2 创业发展及成熟期管理架构

随着客户数量和交付规模增长，拟将初期兼任职责逐步拆分为产品研发、质量安全、交付服务、市场商务和财务综合等职能。组织扩展以真实工作量为前提，必要时引入专业外部服务。



图 5-4 创业发展及成熟期拟定管理架构

质量安全职能拟保留重大问题的发布阻断权；销售承诺涉及新增功能、交付期限或服务保障时，由研发和交付共同评估，避免商业承诺超出产品能力。

人员考核围绕部门实际职责展开：研发关注功能质量与维护效率，质量岗位关注问题识别和复核有效性，交付岗位关注验收及问题解决，商务岗位关注有效转化与回款。激励安排综合考虑长期贡献和客户价值，具体薪酬及权益方案在经营主体和资金条件明确后确定。

通过上述安排，PI OS 将逐步形成从需求、研发、测试到交付和服务的责任体系，使技术成果能够稳定转化为客户价值，并为后续创业发展提供组织支撑。

第六章财务分析与融资计划

PI OS 以企业部署适配、年度产品服务与持续维护为主要商业化方向。财务测算以客户付费和标准化交付为核心，不以科研经费、免费测试规模或行业市场规模直接替代未来经营收入。

现有盖章科研合作协议约定研发经费为 113.3 万元（含税），其中不含税金额 110 万元、税额 3.3 万元。该合同属于华为与天津大学之间的科研合作安排，科研收支与未来创业经营收支分别管理。后续商业化还需结合协议约定完成成果权属、使用范围和必要授权核查。

本章以 2027 年作为商业交付测算起点。2027—2029 年的客户数量、价格、人员配置与融资规模均为基于当前产品规划形成的情景测算，后续将根据实际订单、报价、交付成本和回款情况滚动调整。

6.1 基本会计与测算假设

未来经营主体拟按照《企业会计准则》建立核算制度，以人民币为记账本位币，按公历年度编制财务信息。为保证经营测算可复核，本章统一采用以下口径：

2026 年定位为研发验证和创业筹备期，科研项目收支与未来创业经营收支分开管理，不将已有科研经费转列为公司营业收入。

暂以 2027 年完成必要商用授权并启动商业交付为测算起点；营业收入按不含增值税金额列示，合同金额、会计收入与实际现金回款分别统计。

2027—2029 年年初设备购置预算分别为 10 万元、3 万元和 5 万元，按 5 年直线法、预计净残值为零测算，年度折旧分别为 2.00 万元、2.60 万元和 3.60 万元。

人员预算按 4 人、5 人、6 人的年度平均全职等效规模（FTE）测算，每人每月综合雇佣成本暂按 2 万元计，年度人员预算分别为 96 万元、120 万元和 144 万元。

客户回款按当年收入的 85% 当年收回、14% 次年收回、1% 最终无法收回进行现金需求测算；新增项目优先争取预付款或分阶段付款。

研发投入主要用于核心功能完善、国产运行环境适配、测试验证、部署工具和维护文档建设。研究阶段支出按当期投入考虑；软件、专利或技术许可只有在经营主体拥有或控制相关权利并满足资产确认条件时，才纳入无形资产核算。设备购置进入现金流测算，设备折旧进入经营测算，避免重复计入。

由于未来经营主体、纳税人类型和交易结构尚未最终确定，本章三年经营表采用税费前口径。正式商业化后，将依据实际合同与主体情况核算企业所得税、增值税及相关附加税费。

数据与政策依据

- 国家统计局：《2025 年城镇单位就业人员年平均工资情况》（2026 年 5 月 15 日）。
 - 《中华人民共和国增值税法》（2026 年 1 月 1 日起施行）及财政部、税务总局相关衔接政策。
 - 财政部、税务总局关于小型微利企业所得税优惠的现行政策。
 - 科研合作经费、成果权属及披露边界以已盖章合作协议和后续授权文件为准。
-

6.2 收入预测

PI OS 的收入测算采用“部署适配项目数 × 平均项目单价 + 实际服务期限 × 年度产品服务单价”的方式。部署适配平均单价暂设为 8 万元/项目，年度产品服务平均单价暂设为 6 万元/客户年。2027—2029 年分别完成 4 个、8 个、12 个部署项目，当年实际服务量分别折合 3 个、10 个、22 个完整客户年。托管资源收费、渠道分成、政府补贴等尚未形成稳定依据的收入暂不纳入测算。

表 6-1 PI OS 收入情景测算（单位：万元）

项目	计算依据	2027 年	2028 年	2029 年
部署适配收入	交付项目数 ×8 万元	32.00	64.00	96.00
年度产品服务收入	完整客户年数 ×6 万元	18.00	60.00	132.00
生态合作等其他收入	暂不纳入	0.00	0.00	0.00
收入合计	—	50.00	124.00	228.00

注：“客户年”反映实际服务期限，例如 2 家客户各接受半年服务，合计为 1 个客户年。

图6-1 2027—2029年收入结构演进图




图 6-1 2027—2029 年收入结构演进图

6.2.1 年度产品服务收入

年度产品服务拟涵盖经授权的软件使用、版本维护、兼容支持及约定的问题处理。该业务的增长重点不在单次项目数量，而在持续服务能力和客户续费。测算中，年度产品服务收入占比由 2027 年的

36.0% 提升至 2029 年的 57.9%，意味着商业模式逐步由一次性部署向持续服务转移。

后续应通过付费试点持续记录价格接受度、支持工时、续费原因和客户流失原因，并据此调整服务边界与年度价格。

6.2.2 部署适配与生态合作

部署适配收入主要来自环境检查、系统接入、安装配置、上线支持和约定培训等工作。测算中的 8 万元为平均项目参数，实际报价应根据客户环境复杂度、改造范围和驻场需求确定，避免以固定低价承接超出标准交付边界的定制需求。

在商用授权和责任边界明确后，PI OS 可进一步探索与软件厂商、云服务商或系统集成商联合交付。现阶段尚未形成稳定分成协议，因此相关收入不进入三年基准测算。

6.3 成本分析

PI OS 初期以客户自有服务器或云环境部署为主，公司主要承担产品研发、测试验证、交付支持和市场拓展投入，不预设自建大规模公共算力设施。

表 6-2 PI OS 年度经营投入情景 (单位：万元)

成本项目	预算依据	2027 年	2028 年	2029 年
人员综合成本	4/5/6 名 FTE×24 万元/年	96.00	120.00	144.00
测试、云资源与工具	按阶段设置支出上限	8.00	12.00	18.00
市场与客户拓展	调研、演示、差旅及渠道活动	6.00	10.00	16.00
办公及专业服务	办公、财务、法律等非人工支出	8.00	10.00	14.00
技术许可及第三方支持	未取得报价的预留预算	8.00	12.00	16.00
经营性现金支出小计	不含设备购置和税费	126.00	164.00	208.00
设备折旧	按 6.1 假设计算	2.00	2.60	3.60
信用损失测算	当年收入 ×1%	0.50	1.24	2.28
经营成本合计	用于税费前经营测算	128.50	167.84	213.88

注：技术许可及第三方支持为预算预留项，后续应根据实际授权方式和报价更新。

表 6-3 收入与经营成本对照 (单位：万元)

项目	2027 年	2028 年	2029 年
收入	50.00	124.00	228.00
经营成本合计	128.50	167.84	213.88

项目	2027 年	2028 年	2029 年
税费前经营测算结余	-78.50	-43.84	14.12

基准情景下，2029 年税费前经营测算结余转正，但前两年的累计投入尚未收回。敏感性测试显示，经营结果对收入兑现和人员成本较为敏感：若 2029 年收入较基准情景下降 20%，税费前结余约为 -31.02 万元；若 2029 年人员综合成本增加 20%，结余约为 -14.68 万元。

因此，经营重点应放在提高交付复用率、提升持续服务收入占比，并验证客户是否愿意按能够覆盖完整交付成本的价格采购。




图 6-2 三年收入、经营成本与结余趋势图

6.4 融资计划

融资需求依据经营性现金缺口推算。按照回款假设，当年客户现金回款 = 当年收入 × 85% + 上年收入 × 14%。

表 6-4 PI OS 基础现金需求测算 (单位：万元)

项目	2027 年	2028 年	2029 年
客户现金回款	42.50	112.40	211.16
经营性现金支出	126.00	164.00	208.00

项目	2027 年	2028 年	2029 年
设备购置支出	10.00	3.00	5.00
融资前现金净额	-93.50	-54.60	-1.84

注：折旧和信用损失准备不重复作为现金支出扣除；表内尚未全面计入税费、押金、保证金及月内收支时差。

虽然 2029 年税费前经营测算结余转正，融资前现金净额仍为 -1.84 万元，说明项目除关注盈利能力外，还需要管理客户验收和回款节奏。

6.4.1 首轮资金需求

按照基准情景，2027—2028 年累计基础现金缺口为 148.10 万元。考虑客户回款延迟、授权费用变化、采购时点和交付返工等不确定因素，以基础现金缺口的 20% 设置安全缓冲，约为 29.62 万元，对应测算资金需求约 177.72 万元。因此，首轮融资目标取整为 180 万元。

表 6-5 首轮资金需求构成 (单位：万元)

项目	金额
首两年经营性现金支出	290.00
首两年设备购置支出	13.00
减：预计客户现金回款	154.90
基础资金缺口	148.10
安全缓冲 (基础缺口 ×20%)	29.62
测算资金需求	177.72
首轮融资目标 (取整)	180.00




图 6-3 首轮资金需求形成图

6.4.2 资金使用与分阶段控制

资金优先用于产品化研发、命题指定环境适配、测试验证、首批客户交付和必要经营保障。正式融资前重点完成以下准备：

明确经营主体、成果商用权限以及合作协议中的使用与披露限制。

形成可验收的产品版本、标准交付边界和复现材料。

通过客户访谈、付费试点或订单验证价格、业务量和续费判断。

补齐逐月现金预算、主要采购报价和人员投入计划。

项目采用分阶段投入方式：产品验收前控制非必要营销投入和人员扩张，形成付费交付后再根据销售与支持瓶颈增加人员。若前两年客户回款较基准情景减少 20%，将额外占用约 30.98 万元资金，已接近当前安全缓冲上限，因此招聘、设备采购和重大定制项目需要结合现金余额滚动决策。后续融资以可复制交付、续费和回款质量为主要依据；资本退出以战略并购或后续融资中的股权转让为主要可选路径，待业务规模和治理基础成熟后再评估资本市场路径。

第七章风险分析

PI OS 面向企业智能体的高密度部署需求，通过运行时扁平化、动态资源卸载和智能内存共享，提高有限服务器资源的利用效率。项目已完成现阶段核心代码开发，后续将围绕命题环境适配、产品交付和商业转化推进。随着项目从研究验证走向企业应用，需要重点管理市场接受度、运行可靠性、资金投入和成果使用等风险。

7.1 风险识别

7.1.1 市场风险

1. 技术收益与客户采购需求存在差异

PI OS 的商业价值在于帮助客户利用相同设备承载更多智能体任务，降低部署和运行成本。但不同客户的业务结构存在差异：部分任务等待时间较短，可回收的资源有限；部分客户的主要开支来自模型调用，沙箱资源所能节省的占比有限，对整体成本的改善不明显。因此，实验中的性能提升需要结合客户实际业务，才能判断是否具有采购价值。

2. 客户验证周期较长

企业引入基础软件通常需要经过兼容性测试、安全审查、试运行和采购审批。即使客户认可技术方案，也可能因现有系统改造成本、预算安排和运维习惯而推迟采购，影响项目收入形成的速度。

3. 竞争与客户集中风险

云平台、智能体开发平台和沙箱服务商可能通过价格调整、产品升级或捆绑服务参与竞争。若项目早期对单一合作方依赖过高，其需求调整或采购延期，可能使项目在短期内出现收入缺口。




图 7-1 PI OS 与主要竞争方案的定位对比

7.1.2 操作风险

1. 资源优化影响任务连续性

动态资源卸载需要在适当时机保存任务状态，并在任务继续执行时准确恢复。若状态保存不完整、恢复顺序错误或异常处理不足，可能导致任务中断、结果错误或外部操作重复执行，进而影响客户业务连续性。

2. 高密度部署放大资源波动

多个智能体同时恢复运行时，可能集中申请内存和读取存储，形成瞬时资源高峰。若调度策略不当，单个任务的异常可能波及同批其他任务，降低整体服务稳定性。

3. 研发与交付衔接不足

核心代码完成后，仍需完善安装部署、监报告警、升级回退和故障处理等工程能力。若过早扩大交付范围，可能出现技术人员长期投入客户现场、维护成本增加和版本管理混乱等问题。

7.1.3 财务风险

1. 研发投入与收入形成存在时间差

项目需要持续投入人员、测试设备、基础软件适配和客户验证，而商业收入取决于合同签订、交付进度与客户验收。当资金集中投入而收入回款滞后于交付进度时，可能出现阶段性现金流缺口。

2. 定制开发侵蚀项目利润

不同客户的操作系统、业务工具和部署要求存在差异。若报价未充分考虑适配、维护和售后成本，即使取得订单，也可能因交付投入过高而难以形成合理利润。

3. 可用资金判断失准

科研合作经费、创业投入和经营收入具有不同的使用范围与核算要求。合同约定金额也可能分阶段支付，若将合同约定金额全部视为可立即动用的经营资金，可能因提前投入而导致预算超支。

7.1.4 法律风险

1. 科研成果商业化权属风险

PI OS 的研究基础涉及校企合作，相关代码、技术文档和新增成果的使用，需要结合合作协议确认权属及授权范围。如果商业化主体、许可方式和收益安排未明确，可能影响产品销售、融资和后续合作。

2. 开源软件与第三方依赖风险

项目使用的操作系统、虚拟化组件和工具包可能适用不同的开源许可证（如 GPL、Apache 2.0、MIT、MPL 等）。若未能识别相关许可证义务，可能影响代码分发、产品交付，甚至带来客户合规使用风险。

3. 合作信息披露风险

企业合作信息、合同内容及研发资料可能受到保密约定限制。宣传材料、赛事展示和融资沟通若超

出允许披露的范围，可能影响合作关系及项目信誉。

7.1.5 数据与隐私风险

1. 跨客户数据边界不清

不同客户访问权限划分不清，或共享范围、日志记录和任务清理机制不完善，可能出现跨任务数据泄露、凭据误用和敏感信息残留。

2. 敏感信息留存风险

资源卸载形成的状态文件、运行日志及共享内存对象可能包含客户源代码、业务文件、访问凭据等信息，留存不当会直接损害客户信任。

7.1.6 环境风险

1. 部署环境变化影响运行效果

处理器架构、操作系统版本、存储性能和业务任务差异，都可能影响 PI OS 的资源节省与任务恢复效果。研究环境中的结果不能直接代表所有企业环境中的表现，命题指定环境与客户实际环境均需分别验证。

2. 客户预算和行业需求变化

企业信息化预算调整、智能体应用落地节奏变化以及采购政策调整，可能改变客户的投资优先级。如果产品开发和市场拓展节奏与实际需求脱节，可能增加资金和人员投入压力。

7.1.7 供应链风险

1. 上游更新与接口调整

操作系统、虚拟化组件、语言环境、工具包和外部模型服务的版本更新、接口调整、服务中断或支持策略变化，会增加适配成本，影响复现与交付。

2. 单点依赖

若对单一软件组件或服务商依赖较强，其停止维护、调整价格或发生故障时，项目可能缺乏替代方案。

7.1.8 风险评估矩阵

采用“发生概率（高/中/低）×影响程度（高/中/低）”两个维度，对 7.1.1–7.1.7 识别的各类风险进行定级，并据此确定管理优先级。优先级参考以下规则：

高：概率与影响至少一项为“高”，且另一项不低于“中”

高风险类需重点管理、持续监测；

中：概率与影响均为中，或一项高但另一项低

中风险类纳入常规管理；

低：概率与影响均为低

低风险类可接受，按需关注。

表 7-1 PI OS 风险评估矩阵

风险类别	发生 概率	影响 程度	优先级	关键风险点	触发信号
市场风险	高	高	高	技术收益与采购价值错位、验证周期长、客户集中	试点无法转化为付费、单一客户收入占比过高
操作风险	中	高	高	状态恢复错误、并发资源高峰、交付工程能力不足	任务成功率下降、恢复后结果错误、线上故障增多
数据与隐私 风险	中	高	高	跨客户数据边界不清、状态文件/日志敏感信息残留	权限隔离测试未通过、敏感数据脱敏覆盖率低
财务风险	中	中	中	研发投入与回款时间差、定制侵蚀利润、可用资金误判	可用资金低于保障线、项目毛利持续偏低
法律风险	中	中	中	成果权属不明、开源许可证义务、披露越界	权属清单不完整、许可证审查发现不合规、披露未获确认
供应链风险	中	中	中	上游更新或故障、组件单点依赖	依赖组件停止维护、外部服务连续故障、交付难以复现
环境风险	低	中	中	部署环境差异、客户需求与预算变化	分环境测试结果不一致、客户预算调整

结合上表，市场、操作、数据与隐私三类应作为全周期重点；财务、法律、供应链纳入常规管理；环境风险结合命题试点持续跟踪。

7.2 风险防范及措施

以下措施将随命题验收、客户试点和商业化进程逐步落实，并通过测试记录、交付记录和经营数据检查执行效果。

7.2.1 市场风险

1. 以真实业务验证采购价值

优先面向具有多智能体并发需求的代码开发、自动化测试等场景开展试点。使用相同设备和任务，对比部署前后的任务成功率、完成时间、资源占用和维护投入，形成客户能够核对的价值报告。

客户收益测算应同时纳入新增存储开销、软件服务费用与部署维护成本，以实际减少的支出或新增的有效处理能力作为采购依据。

2. 分阶段推进客户转化

采用“需求确认—小规模验证—付费试点—扩大部署”的推进方式。每个阶段明确验证目标、投入范围和结束条件，及时识别不适合的客户场景，提高售前投入效率。

3. 建立可复用的产品和客户结构

围绕共性需求形成标准版本、部署文档和服务套餐，减少单一客户定制对研发方向的牵引。在完成初期试点后，逐步拓展其他智能体平台和企业开发团队，降低客户集中风险。

7.2.2 操作风险

1. 建立安全的状态保存与恢复流程

采用“保存完成并校验后释放资源”的处理方式，为状态数据记录版本和完整性信息。对于涉及文件写入、接口调用等操作的任务，明确恢复边界，防止任务恢复后错误重复执行。

当优化机制出现异常时，支持关闭相关功能、回到已验证的运行方式，保障任务连续性。

2. 控制并发恢复和资源峰值

设置统一的内存预算与恢复并发限制，为管理服务和异常恢复保留必要资源。面对多个任务同时恢复的情况，通过排队、限流和调整预取规模平滑资源需求。

命题测试统一统计管理面、沙箱、共享池及相关缓存的实际内存占用，核验是否满足总内存限制，避免遗漏资源开销。

3. 完善发布和交付管理

建立代码审查、自动化测试、小范围试运行和版本回退流程。重点测试保存中断、磁盘空间不足、网络断连、任务取消和集中恢复等情况。

交付时同步提供安装说明、兼容性清单、监控指标和故障处理手册，逐步提高客户自主部署与维护能力。

7.2.3 财务风险

1. 按阶段安排投入

将资金投入与指定环境验证、首个付费试点、标准化交付等里程碑对应。前一阶段达到约定目标后，再决定下一阶段的设备采购和人员扩充规模。

2. 加强现金流管理

分别记录科研经费、创业投入和经营收支，按月检查可用资金、应收款项和未来支出。客户合同合理设置预付款、阶段验收款和尾款，减少长期垫资。

3. 以完整交付成本制定报价

报价时计入适配开发、测试资源、部署支持、持续维护及潜在返工成本。对超出标准服务范围的需求，明确工作量、费用与交付时间，降低无边界定制带来的利润损失。

7.2.4 法律风险

1. 明确成果使用与转化安排

在商业化前，梳理既有成果、合作项目新增成果和第三方组件，形成权属与使用范围清单。根据实际权属推进技术许可、成果转化或其他合作方式，并明确维护责任和收益安排。

2. 建立开源依赖审查机制

记录主要依赖的来源、版本和许可证，检查交付方式是否符合相应要求。新增组件或调整开源方式时同步复核，保留必要的授权和说明文件。

3. 规范合同与对外披露

对涉及合作企业名称、合同信息、研发数据及代码的公开材料，按协议完成确认。客户合同明确服务内容、验收标准、数据处理责任和售后边界；成果转化与融资文件由具备相应能力的专业人员审核。

7.2.5 数据与隐私风险

1. 限定共享内容和访问范围

不同客户的任务目录、凭据和可写状态分别管理。共享优先限定为授权范围内的基础只读内容，客户私有代码、业务数据和访问身份不进入跨客户公共共享范围。

2. 加强状态文件与日志保护

对状态文件设置访问控制，并根据数据敏感程度配置加密保护。日志仅记录定位问题所需的信息，对令牌、密码和敏感输入进行脱敏，减少不必要的数据留存。

3. 建立数据清理与事件响应机制

明确任务结束、客户退出和服务终止后的数据清理规则。发生疑似泄露时，及时隔离受影响任务、撤销相关凭据、保留调查记录，并按照适用要求与客户约定开展处置和通知。



图 7-2 多租户数据与状态隔离边界

7.2.6 环境风险

1. 建立分环境验证体系

优先围绕命题要求的 openEuler、Conch 和 StratoVirt 环境开展适配，分别记录不同处理器架构、系统版本和任务类型的测试结果。

在总内存限制为 16GB、每个沙箱配置为 2U8G、关闭 swap 等条件下，验证指定任务的完成情况和有效并发能力，使测试结果与命题验收直接对应。

2. 持续维护兼容性范围

发布经过验证的软硬件兼容性清单。操作系统、镜像或关键组件升级后，重新检查功能、性能与隔离效果，并为客户保留稳定版本及升级回退路径。

3. 根据需求调整商业推进节奏

结合客户预算和试点结果安排研发优先级。需求不足时控制扩张投入，优先完善能够直接改善客户成本、稳定性和部署效率的功能。

7.2.7 供应链风险

1. 保证构建和交付可复现

固定关键代码版本与镜像标识，保存依赖清单、构建脚本和必要的软件包，降低上游更新对已有交付版本的影响。

2. 降低单点依赖

对关键组件和外部服务评估替代方案，将可变接口封装在适配层。替代方案经过验证后再纳入交付范围，逐步提高产品迁移能力。

3. 区分外部故障与产品故障

监控模型接口、存储和网络服务的运行状态，分别记录外部服务失败与沙箱运行失败。针对外部故障设置超时、受控重试和任务暂停机制，减少无效重试造成的资源浪费。

7.2.8 风险—对策映射汇总表

下表将 7.1 识别的各类风险与 7.2 的对策条目一一对应，并标明责任主体与可量化的监测指标，便于按里程碑检验执行效果。

表 7-2 风险与对策映射表

风险类别	主要对策（对应条目）	责任主体	监测指标 / 验证方式
市场风险	以真实业务验证采购价值、分阶段推进客户转化、建立可复用的产品与客户结构（7.2.1）	市场与售前、产品	试点客户数及转化率、单一客户收入占比、客户续约与拓展情况、价值报告数据
操作风险	建立安全的状态保存与恢复流程)、控制并发恢复和资源峰值、完善发布和交付管理（7.2.2）	研发、测试	任务成功率、恢复正确性、内存占用、关键故障场景测试覆盖、线上故障数
财务风险	按阶段安排投入、加强现金流管理、以完整交付成本制定报价（7.2.3）	财务、经营	月度可用资金与应收/预收、各经费科目使用、项目毛利、里程碑达成
法律风险	明确成果使用与转化安排、建立开源依赖审查机制、规范合同与对外披露（7.2.4）	法务、成果转化	权属与使用范围清单、许可证合规审查记录、对外披露确认记录
数据与隐私风险	限定共享内容和访问范围、加强状态文件与日志保护、建立数据清理与事件响应机制（7.2.5）	研发、安全、运维	访问权限隔离测试、敏感数据脱敏覆盖率、数据清理执行率、疑似泄露事件数及响应时长
环境风险	建立分环境验证体系)、持续维护兼容性范围、根据需求调整商业推进节奏（7.2.6）	研发、测试、产品	分环境测试报告、兼容性清单更新频率、版本回退成功率
供应链风险	保证构建和交付可复现、降低单点依赖、区分外部故障与产品故障（7.2.7）	研发、运维	依赖清单与构建脚本完备、替代方案验证情况、外部服务故障率与恢复时长

7.3 风险资本退出

PI OS 将在商业化主体、成果使用权限和经营模式明确后推进融资。以下为拟议的退出安排，具体方式以届时经营状况、投资协议和适用法律为依据。

7.3.1 项目未达预期目标的退出策略

如果项目持续未达到技术交付或商业转化目标，团队将首先分析原因，评估通过缩小产品范围、调整目标客户或转向适配服务能否形成可持续业务。

若调整后仍缺乏可行的经营路径，可与投资者协商股权转让、业务并购或有序终止经营。资产处置仅限商业化主体实际拥有且可依法转让的资产，涉及学校或合作企业的成果，应按照权属和授权约定处理。

退出过程中同步安排客户服务交接、数据迁移与合同履行，以降低对客户及合作方业务连续性的影响。

7.3.2 设定触发条件的退出策略

拟在投资协议中明确阶段目标、检查周期和整改期限，将技术交付、客户转化及现金流状况作为持续评估依据。

可协商的触发情形包括：关键验收目标连续未完成、试点长期无法转化为付费业务、可用资金低于约定运营保障线，以及出现影响持续经营的重大安全或权属问题。

触发条件出现后，先启动经营复核和限期整改；整改后仍无法恢复正常推进的，再协商后续融资调整、股权转让或退出安排，避免因单次波动仓促终止项目。

7.3.3 保护投资者利益的退出策略

项目拟通过定期财务报告、关键经营指标披露、重大支出审议和成果权属核验，提高投资者对资金使用及项目进展的可见度。融资和退出定价以真实经营数据及可核验资产为依据，不承诺保本或固定收益。

股权转让、并购等退出方式，应明确估值依据、付款安排和后续责任。涉及公司清算时，依法清偿相关费用和债务后，股东才参与剩余财产分配；股权投资者不当然优先于债权人受偿。

第八章团队介绍

PI OS 项目团队由软件工程、网络安全、人工智能及计算机科学与技术等专业的本科生、硕士生和博士生组成。团队围绕华为“高密部署智能体沙箱引擎”命题，将底层系统研究、工程验证与企业应用需求结合，推进技术实现、实验复核、商业测算和成果转化。

团队成员根据研究与工程经验承担系统研发、智能体机制说明、测试验证、安全分析、财务测算、文档规范和项目统筹等工作，并通过统一术语、数据复核与版本管理保持跨模块协作。

8.1 主创团队

8.1.1 团队构成与能力互补

项目以运行时扁平化、动态资源卸载和智能内存共享为核心技术方向，目前已完成现阶段核心代码开发。后续重点包括命题指定环境适配、性能与隔离测试、交付文档完善，以及在权属和授权边界明确后推进客户验证。

团队能力可归纳为系统基础设施、智能体运行优化、测试验证体系与产业转化体系四类，研究侧依托天津大学科研平台，产业侧依托与华为的技术合作，形成技术研发、企业需求、学生成长和成果转化相互衔接的协作结构。

表 8-1 PI OS 项目成员与现阶段分工

姓名	年级与专业	现阶段职责
张纪同	2023 级本科·软件工程	项目统筹、命题需求对齐、计划书整合与答辩组织
陈奕池	2026 级博士·软件工程	核心代码实现、运行时机制研发与技术评审支持
刘国威	2024 级博士·计算机科学与技术	性能优化与技术路线可行性论证支持
周以恒	2026 级硕士·计算机科学与技术	系统研究、技术文档审核与方案复核支持
范文丽	2024 级本科·软件工程	财务分析与融资计划、团队材料整理与协作证据
李子鹏	2025 级本科·计算机科学与技术	测试数据复核、指标计算、测试环境与验收材料
刘书雄	2024 级本科·人工智能	智能体任务流程、动态卸载与预取机制说明
王子硕	2025 级本科·网络安全	隔离与共享安全、数据保护及风险管理材料
王新雅	2025 级本科·软件工程	文档规范、来源整理、术语统一与复现说明
张思淼	2025 级本科·软件工程	运行时扁平化方案、组件职责与架构说明

注：表中职责对应当前项目推进阶段，具体贡献通过代码、测试数据、文档版本和协作记录等材料留存。



8.1.2 协作与质量控制机制

项目采用模块责任制和交叉复核机制。每项核心内容明确负责人、输入材料、结论和复核方式，技术指标保留原始数据、脚本与环境说明，经营数字保留计算依据与关键假设。

表 8-2 团队协作与质量控制机制

机制	执行方式	作用
页面/模块责任制	每项核心内容明确负责人、输入材料、结论与复核人	明确责任边界
证据留存	技术指标保留原始数据、脚本、环境说明和复现步骤；经营数字保留计算依据	保证材料可复核
交叉复核	技术页由非主责成员检查逻辑和可读性，关键数据至少完成一次独立复算	降低单点错误
统一口径	项目名称、技术状态、指标口径、商业化边界在计划书、PPT 和答辩中保持一致	提高交付一致性
版本与交接	保留代码、测试报告、计划书和展示材料版本；关键模块同步整理部署方法和待办	保障项目连续性

底层系统开发、工程测试、财务测算和商业表达相互校验：技术结果决定可对外说明的产品能力，测试数据支撑性能与价值判断，财务测算则反向约束人员扩张和客户定价，使技术、市场和财务保持同

一套项目口径。

8.1.3 学生成长与项目持续性

团队把企业真实需求转化为可执行的学生实践任务。新成员从环境搭建、测试复现、文档完善和小范围问题修复开始参与，关键修改经评审后合入；个人贡献以任务成果、复核质量和协作记录共同体现。

随着项目进入商业化阶段，团队将根据真实订单和交付负荷补充产品、运维及商务能力。新增岗位以实际工作瓶颈为依据，并通过技术文档、权限交接和备份负责人机制降低人员变化对项目连续性的影响。

8.2 指导教师

本项目指导教师为天津大学赵来平教授。赵来平教授研究领域为计算系统，研究方向包括数据中心、云计算、软件定义网络 and 智能运维，主讲云计算课程并承担研究生指导工作，其研究方向与 PI OS 涉及的智能体运行环境、计算资源管理和系统运行效率优化具有较高相关性。

项目推进过程中，指导教师主要负责技术路线、实验方法和关键问题把关，具体的方案分析、代码实现、实验复核、财务测算和材料整理由团队成员按分工完成。该协作方式既保证技术方向和实验方法的规范性，也保留学生团队在项目实现与交付中的主体作用。

证明材料



由

华为技术有限公司

与

天津大学

项目名称：Agentic运行时分层状态卸载与共享技术合作项目

协议编号：TC20260325025



郑亮

证明材料 1 技术合作项目协议封面



文档名称: Agentic运行时分层状态卸载与共享技术合作项目
合同编号: TC20260325025

		关于 Agentic 运行时资源优化的创新 Idea	1 份	提供创新 Idea 并获华为专利评审会 (PRB) 评审通过	
--	--	----------------------------	-----	--------------------------------	--

2.2 进度报告

合作方应按月度或华为要求以书面形式提交项目进度报告，以使华为及时了解项目进度。

2.3 变更

在本协议履行过程中，如因华为需求、进度变更及其他原因引起的工作任务变更，华为项目负责人应以书面《变更单》的形式提出变更需求，合作方应积极配合按照变更后的需求完成工作任务。

- (1) 如果工作任务变更对本协议总金额不产生影响，双方项目负责人书面(含电子邮件)同意《变更单》后可执行变更。
- (2) 如果在项目交付周期内的累计工作任务变更导致本协议总金额变化，双方应进行友好协商并以书面形式签署补充协议，以约定变更后的工作任务清单、价格、交付进度及验收标准等。对于补充协议签署前，合作方自行投入的工作量，华为可不予支付。

3. 研发人员

- 3.1 合作方应当指派具有足够资质和能力的自有研发人员（“研发人员”）承担本项目项下的开发工作，关键研发人员信息详见“表：项目关键研发人员清单”。合作方应保证关键研发人员的资质满足华为要求并按双方约定真实投入，华为可对合作方关键研发人员的资质进行核验并要求合作方更换不合格研发人员。因合作方研发人员离职引起的更换，应提前三十（30）天书面通知华为，并用相同或更高资质的研发人员进行替换，合作方应确保新老研发人员尽合理努力完成交接，交接期限应不少于十五（15）天。为明确起见，若合作方项目负责人更换，或其他研发人员更换导致本项目项下的开发工作难以按照本协议约定完成，华为有权按照本协议正文第12.2(4)条终止本项目，并要求合作方返还本协议已支付费用中尚未使用的部分。

表：项目关键研发人员清单

序号	姓名	项目职务	资格及项目内职责描述	投入的工作量 (单位：人·月)
3	陈奕池	博士研究生	面向 AI Agent 的分层状态卸载技术研发	10
9	周以恒	硕士研究生	面向 AI Agent 的按需状态恢复技术研发	10

- 3.2 双方指定下列项目负责人，负责开发过程中的项目管理。

表：双方项目负责人清单

补充证明材料

技术合作成果应用证明

成果名称	面向服务器无感知计算的函数缓存技术
应用单位	华为云计算技术有限公司
单位注册地址	深圳市龙岗区坂田华为总部办公楼
应用单位联系人/电话	郝月婵/18632141072
起止时间	2022 年 10 月 1 日至今

具体应用情况：

天津大学赵来平教授与我单位华为云 PaaS 技术创新 Lab 深度合作，共同开展服务器无感知计算领域研究。2022 年双方签订 CCF-华为胡杨林基金项目《业务特性感知的资源调度技术》(CCF-HuaweiSE2022006) 研究。在项目研究期间，赵来平教授团队提出了一种面向服务器无感知计算场景的函数缓存方案，该方案提出了跨机协同的中心式缓存管理策略，以优化降低函数缓存实例所占用的内存资源，并提高缓存的命中率，进而提高函数应用的执行性能。该成果已成功应用于本单位的华为云“Function Graph”计算服务中，每日为超过 10 亿次函数访问请求提供缓存服务，在保障 99.8%的缓存命中率的同时，降低内存资源的使用 15%-20%，为新一代高性能服务器无感知计算平台的构建提供了有力支撑。

单位公章：

2023 年 9 月 28 日

证明材料 3 华为技术合作成果应用证明

应用证明

腾讯科技（深圳）有限公司是中国领先的科技企业之一。公司 AI 平台部聚焦决策 AI 和生成式 AI 两大技术研发方向，致力于探索人工智能与游戏娱乐行业的深度融合，打造“开悟”AI 开放研究平台，全面支持大模型在游戏业务上的训练与推理。在面对多种训练范式、异构算力和大模型训练状态管理等挑战时，传统内存管理方案难以兼顾资源效率与训练性能，制约了大模型训练任务在生产环境中的高效部署与规模化应用。

鉴于天津大学赵来平教授团队在大模型训练系统与存储优化领域的技术优势，我司与赵来平教授团队围绕多层次内存管理开展了深入合作。天津大学团队提出了多项关键技术：一是提出生命周期驱动的内存管理方法，使训练状态按实际使用周期在 HBM、DRAM 和 NVMe 间迁移，及时释放非活跃状态占用的显存；二是设计 HBM 滚动层窗口，通过动态规划为各层训练状态选择保留、卸载或重计算策略，支持更大的单卡训练负载；三是设计优化器事务窗口及跨层协同调度机制，将页面预取、更新、回写和回收组成流水线，并根据内存及回写压力动态调整资源；四是优化变长算子和集合通信，将 RL、OPD 权重更新阶段的 CPU 侧通信迁移至设备侧执行。基于上述技术，双方联合研发了大模型训练系统 UNMOOR，并在“开悟”平台规模化部署，支持 RL、SFT、OPD 等训练范式及昇腾 910B NPU、NVIDIA GPU 等异构硬件。生产实验表明，UNMOOR 将训练所需加速卡数量降低至四分之一，模型端到端训练时间节省 2.31 倍，优化器阶段执行效率提升 1.49 倍，HCCL 集合通信性能提升 2.41 倍。集群有效吞吐提升 2.18 至 2.30 倍，年化成本节省约 2613 万美元。

天津大学技术先进，为腾讯在大模型训练系统和异构算力平台方向的技术突破与平台演进提供了关键支撑，对公司人工智能基础设施能力和技术竞争力提升起到了关键性推动作用。该证明用于支撑《多元异构计算系统下 Serverless 工作流编排技术研究》项目。

腾讯科技（深圳）有限公司

2026 年 9 月 8 日

证明材料 4 腾讯科技（深圳）有限公司应用证明