

应用证明

腾讯科技（深圳）有限公司是中国领先的科技企业之一。公司 AI 平台部聚焦决策 AI 和生成式 AI 两大技术研发方向，致力于探索人工智能与游戏娱乐行业的深度融合，打造“开悟”AI 开放研究平台，全面支持大模型在游戏业务上的训练与推理。在面对多种训练范式、异构算力和大模型训练状态管理等挑战时，传统内存管理方案难以兼顾资源效率与训练性能，制约了大模型训练任务在生产环境中的高效部署与规模化应用。

鉴于天津大学赵来平教授团队在大模型训练系统与存储优化领域的技术优势，我司与赵来平教授团队围绕多层次内存管理开展了深入合作。天津大学团队提出了多项关键技术：一是提出生命周期驱动的内存管理方法，使训练状态按实际使用周期在 HBM、DRAM 和 NVMe 间迁移，及时释放非活跃状态占用的显存；二是设计 HBM 滚动层窗口，通过动态规划为各层训练状态选择保留、卸载或重计算策略，支持更大的单卡训练负载；三是设计优化器事务窗口及跨层协同调度机制，将页面预取、更新、回写和回收组成流水线，并根据内存及回写压力动态调整资源；四是优化变长算子和集合通信，将 RL、OPD 权重更新阶段的 CPU 侧通信迁移至设备侧执行。基于上述技术，双方联合研发了大模型训练系统 UNMOOR，并在“开悟”平台规模化部署，支持 RL、SFT、OPD 等训练范式及昇腾 910B NPU、NVIDIA GPU 等异构硬件。生产实验表明，UNMOOR 将训练所需加速卡数量降低至四分之一，模型端到端训练时间节省 2.31 倍，优化器阶段执行效率提升 1.49 倍，HCCL 集合通信性能提升 2.41 倍。集群有效吞吐提升 2.18 至 2.30 倍，年化成本节省约 2613 万美元。

天津大学技术先进，为腾讯在大模型训练系统和异构算力平台方向的技术突破与平台演进提供了关键支撑，对公司人工智能基础设施能力和技术竞争力提升起到了关键性推动作用。该证明用于支撑《多元异构计算系统下 Serverless 工作流编排技术研究》项目。

腾讯科技（深圳）有限公司

2026 年 9 月 8 日

